Estatística

Aula 3 — Distribuições de Frequências e Representações Gráficas

Licenciatura em Engenharia Informática

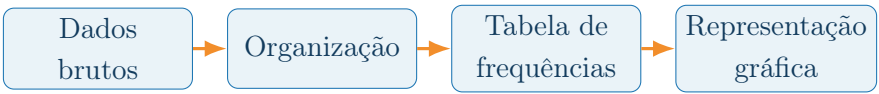
ISLA Santarém - Instituto Politécnico
12 outubro 2026

Objetivos da aula

No final desta aula deverá ser capaz de:

- organizar um conjunto de dados brutos;
- construir tabelas de distribuição de frequências;
- calcular frequências absolutas, relativas e acumuladas;
- agrupar dados quantitativos em classes;
- selecionar uma representação gráfica adequada ao tipo de variável;
- construir e interpretar gráficos de barras, setores, histogramas, polígonos e gráficos acumulados;
- detetar representações estatísticas inadequadas ou potencialmente enganadoras.

Da observação aos dados organizados



Ideia central

Uma lista de observações contém informação, mas a organização permite tornar visível a estrutura dos dados.

Distribuição de frequências

Um primeiro conjunto de dados

Número de erros encontrados em 20 programas durante um teste:

$$2,\ 1,\ 0,\ 3,\ 2,\ 1,\ 4,\ 2,\ 0,\ 1,$$

$$2,\ 3,\ 1,\ 2,\ 0,\ 4,\ 1,\ 2,\ 3,\ 1.$$

Perguntas naturais:

- Qual o número de erros mais frequente?
- Que proporção dos programas tem, no máximo, 2 erros?
- Quantos programas têm menos de 3 erros?

Uma tabela de frequências permite responder rapidamente.

Frequência absoluta — F_i

Definição

A frequência absoluta F_i é o número de observações que pertencem à modalidade ou valor x_i.

Para uma amostra de dimensão n:

$$\sum_{i=1}^{k} F_i = n$$

onde k é o número de modalidades ou valores distintos.

Exemplo

Se 7 dos 20 programas apresentam exatamente 1 erro, então para $x_i = 1$ temos

$$F_i = 7.$$

Frequência relativa — f_i

Definição

A frequência relativa f_i é a proporção de observações pertencentes à modalidade x_i.

$$\boxed{f_i = \frac{F_i}{n}} \qquad \text{e} \qquad \boxed{\sum_{i=1}^{k} f_i = 1}$$

Em percentagem:

$$100 f_i \%.$$

Exemplo

Se $F_i = 7$ e $n = 20$,

$$f_i = \frac{7}{20} = 0,35 = 35\%.$$

Frequência absoluta acumulada — F_a

Definição

A frequência absoluta acumulada F_a corresponde ao número de observações com valor inferior ou igual ao valor considerado.

$$F_a(x_i) = \sum_{j=1}^{i} F_j$$

Importante

As frequências acumuladas fazem sentido quando as modalidades possuem ordem: variáveis ordinais ou quantitativas.

No último valor da distribuição:

$$F_a = n.$$

Frequência relativa acumulada — f_a

Definição

A frequência relativa acumulada f_a é a proporção de observações com valor inferior ou igual ao valor considerado.

$$f_a(x_i) = \sum_{j=1}^{i} f_j = \frac{F_a(x_i)}{n}$$

No último valor:

$$f_a = 1 = 100\%$$

F_i e f_i descrevem uma modalidade; F_a e f_a descrevem o que foi acumulado até essa modalidade.

Tabela de frequências completa

Para os 20 programas do exemplo:

x_i	F_i	f_i	F_a	f_a
0	3	0,15	3	0,15
1	6	0,30	9	0,45
2	6	0,30	15	0,75
3	3	0,15	18	0,90
4	2	0,10	20	1,00
Total	20	1,00	–	–

Leitura

$F_a(2) = 15$: 15 programas apresentam no máximo 2 erros. $f_a(2) = 0,75 (75\%)$.

Verificação rápida de uma tabela

Uma tabela bem construída deve satisfazer:

$$\sum F_i = n, \qquad \sum f_i = 1, \qquad F_a \text{ não decresce}, \qquad f_a \text{ não decresce}.$$

Além disso, no final:

$$F_a = n, \qquad f_a = 1.$$

Erro frequente

Somar as frequências acumuladas não tem interpretação útil. Assim, não se coloca uma "soma" na coluna F_a ou f_a.

Organização dos dados

Variável qualitativa nominal

Considere o sistema operativo principal de 100 computadores:

Sistema operativo	F_i	f_i
Windows	55	0,55
Linux	30	0,30
macOS	10	0,10
Outro	5	0,05
Total	100	1,00

Por que não aparecem F_a e f_a?

Porque as modalidades não têm uma ordem natural. Acumular "Windows + Linux" não possui significado estatístico intrínseco.

Variável qualitativa ordinal

Qualidade percebida da ligação de rede por 80 utilizadores:

Qualidade	F_i	f_i	F_a	f_a
Má	8	0,10	8	0,10
Razoável	20	0,25	28	0,35
Boa	36	0,45	64	0,80
Muito boa	16	0,20	80	1,00

Aqui a acumulação é possível porque existe uma ordem natural entre as modalidades.

Variável quantitativa discreta

Para uma variável discreta, cada valor observado pode constituir uma modalidade:

X = número de falhas diárias de um serviço.

x_i	F_i	f_i	F_a	f_a
0	12	0,40	12	0,40
1	9	0,30	21	0,70
2	6	0,20	27	0,90
3	3	0,10	30	1,00

A tabela preserva os valores exatos e permite leituras acumuladas imediatas.

Quando existem muitos valores distintos...

Tempos de resposta de um servidor, em milissegundos:

$$121,\ 137,\ 143,\ 155,\ 161,\ 168,\ 174,\ 181,\ 189,\ 193, \ldots$$

Uma tabela com uma linha para cada valor seria pouco informativa.

Solução

Agrupar os valores em classes ou intervalos, por exemplo:

$$[120, 140[, \quad [140, 160[, \quad [160, 180[, \quad [180, 200[.$$

O símbolo $[a, b[$ significa $a \leq x < b$.

Amplitude total e amplitude de classe

Se x_{min} e x_{max} forem os extremos observados, a amplitude total é

$$\boxed{A = x_{max} - x_{min}}.$$

Se pretendermos k classes de igual amplitude, uma primeira aproximação é

$$\boxed{h \approx \frac{A}{k}},$$

onde h representa a amplitude de classe.

Exemplo

Se os tempos variam entre 121 e 238 ms, então $A = 117$ ms. Para 6 classes,

$$h \approx 117/6 = 19,5,$$

podendo adotar-se, por conveniência, $h = 20$ ms.

Quantas classes devemos usar?

Não existe uma única resposta correta. Uma regra clássica é a regra de Sturges:

$$\boxed{k \approx 1 + 3,322 \log_{10}(n)}.$$

Para $n = 100$:

$$k \approx 1 + 3,322 \times 2 \approx 7,64,$$

pelo que poderíamos considerar aproximadamente 8 classes.

Mas atenção

A escolha deve também considerar a natureza dos dados, a dimensão da amostra e a facilidade de interpretação. A regra é uma orientação, não uma obrigação.

Centro de uma classe

Para uma classe

$$[a_i, b_i[,$$

o centro da classe é

$$\boxed{c_i = \frac{a_i + b_i}{2}}.$$

Exemplo:

$$[140, 160[\quad \Rightarrow \quad c_i = \frac{140 + 160}{2} = 150.$$

O centro funciona como um valor representativo das observações pertencentes à classe.

Exemplo: dados agrupados em classes

Tempos de resposta de 50 pedidos:

Classe (ms)	c_i	F_i	f_i	F_a	f_a
$[120, 140[$	130	5	0,10	5	0,10
$[140, 160[$	150	11	0,22	16	0,32
$[160, 180[$	170	16	0,32	32	0,64
$[180, 200[$	190	10	0,20	42	0,84
$[200, 220[$	210	6	0,12	48	0,96
$[220, 240[$	230	2	0,04	50	1,00

Representações gráficas

Qual gráfico escolher?

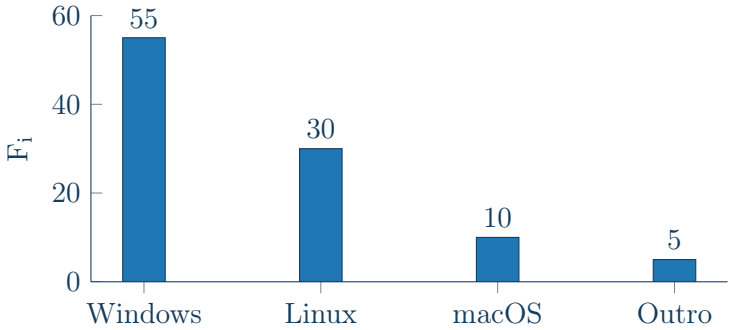
Tipo de dados	Representações adequadas
Qualitativos nominais	Barras, setores
Qualitativos ordinais	Barras ordenadas
Quantitativos discretos	Barras, pontos
Quantitativos contínuos agrupados	Histograma, polígono
Frequências acumuladas	Gráfico acumulado (ogiva)

Princípio

O gráfico deve respeitar a natureza da variável e facilitar a leitura da informação, não apenas tornar a apresentação mais "bonita".

Gráfico de barras

Adequado sobretudo a variáveis qualitativas e quantitativas discretas.



As barras estão separadas: cada barra representa uma categoria ou valor distinto.

Gráfico de setores

Útil para representar a composição de um total quando existem poucas categorias. Se uma categoria tem frequência relativa f_i, o ângulo do setor é

$$\boxed{\alpha_i = 360^\circ f_i}.$$

Exemplo: Linux representa 30% dos computadores:

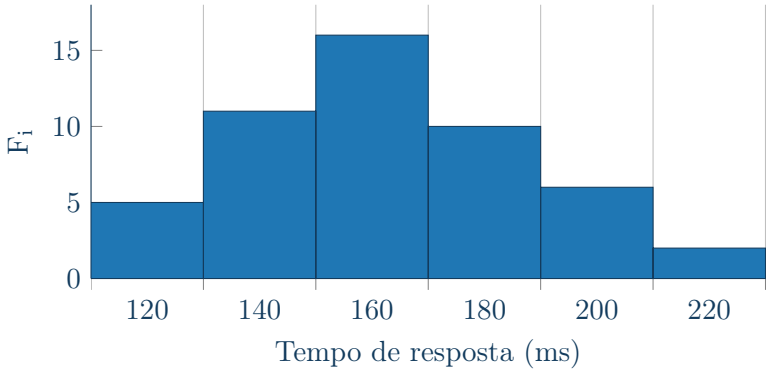
$$\alpha = 360^\circ \times 0,30 = 108^\circ.$$

Limitação

Com muitas categorias ou proporções semelhantes, a comparação visual torna-se difícil; nesses casos, um gráfico de barras é normalmente superior.

Histograma

O histograma é adequado para uma variável quantitativa contínua agrupada em classes.



As barras são contíguas: representam intervalos adjacentes de valores.

Barras ou histograma?

Gráfico de barras

- categorias ou valores discretos;
- barras separadas;
- a ordem pode ser arbitrária em dados nominais;
- a largura da barra não representa um intervalo numérico.

Histograma

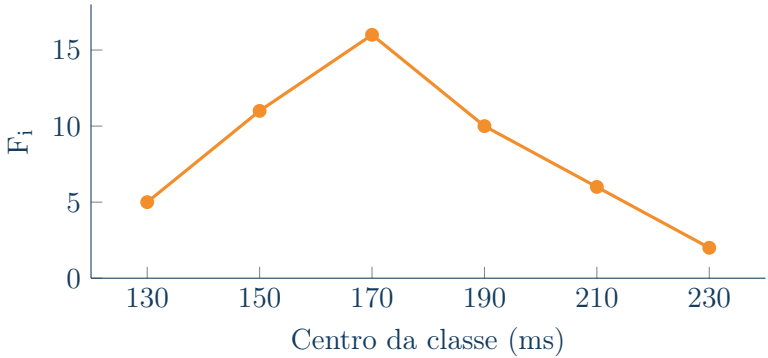
- dados quantitativos contínuos;
- barras contíguas;
- classes ordenadas numericamente;
- cada barra representa um intervalo.

Erro frequente

Um histograma não é simplesmente um gráfico de barras “sem espaços”.

Polígono de frequências

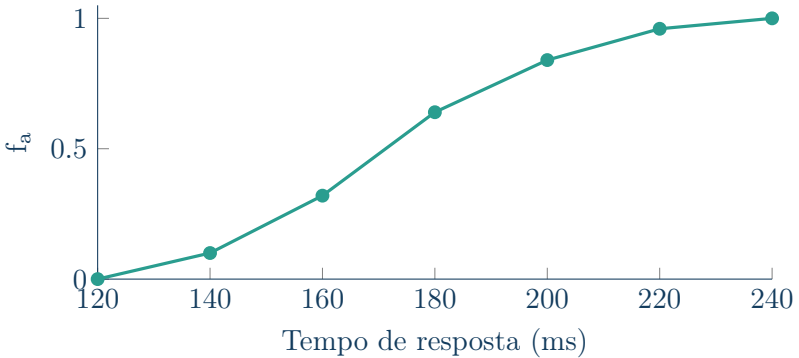
Liga pontos cujas abcissas são os centros das classes e cujas ordenadas são as frequências.



É especialmente útil para observar a forma da distribuição e comparar distribuições.

Gráfico de frequências acumuladas — ogiva

Representa as frequências acumuladas nos limites superiores das classes.



Permite responder visualmente a questões como: "Que proporção dos pedidos tem tempo inferior a 200 ms?"

Interpretação e pensamento crítico

O eixo pode enganar

Considere duas aplicações com tempos médios de resposta de 98 ms e 102 ms. Um gráfico cujo eixo vertical começa em 97 ms pode fazer a diferença parecer enorme.

Boa prática

A escala dos eixos deve ser explicitada e escolhida de modo a não exagerar ou ocultar diferenças. Em gráficos de barras, um eixo que não começa em zero exige especial cuidado.

Um gráfico estatisticamente correto pode ainda assim ser visualmente enganador.

Exercício rápido: complete a tabela

Numa amostra de 40 estudantes, o número de dispositivos ligados à Internet é:

x_i	F_i	f_i	F_a	f_a
1	4	?	?	?
2	10	?	?	?
3	14	?	?	?
4	8	?	?	?
5	4	?	?	?

1. Complete a tabela.
2. Qual a percentagem com, no máximo, 3 dispositivos?
3. Qual a percentagem com mais de 3 dispositivos?

Solução do exercício rápido

x_i	F_i	f_i	F_a	f_a
1	4	0,10	4	0,10
2	10	0,25	14	0,35
3	14	0,35	28	0,70
4	8	0,20	36	0,90
5	4	0,10	40	1,00

- No máximo 3 dispositivos: $f_a(3) = 0,70 = 70\%$.
- Mais de 3 dispositivos: $1 - 0,70 = 0,30 = 30\%$.

Síntese: quatro frequências

Notação	Designação	Interpretação
F_i	Frequência absoluta	número na modalidade/classe
f_i	Frequência relativa	proporção na modalidade/classe
F_a	Frequência absoluta acumulada	número acumulado
f_a	Frequência relativa acumulada	proporção acumulada

$$f_i = \frac{F_i}{n}, \qquad f_a = \frac{F_a}{n}.$$

Síntese da Aula 3

Hoje trabalhámos:

- organização de dados brutos;
- frequências F_i, f_i, F_a e f_a;
- tabelas para dados qualitativos e quantitativos;
- agrupamento em classes, amplitude e centro de classe;
- gráficos de barras e setores;
- histogramas e polígonos de frequências;
- gráficos de frequências acumuladas;
- escolha e interpretação crítica de representações gráficas.

Organizar bem os dados é o primeiro passo para os compreender.

Da organização à interpretação

Agora vamos trabalhar com dados e construir as nossas próprias tabelas e gráficos.