Estatística — Regras de Estudo

1. Conceitos fundamentais

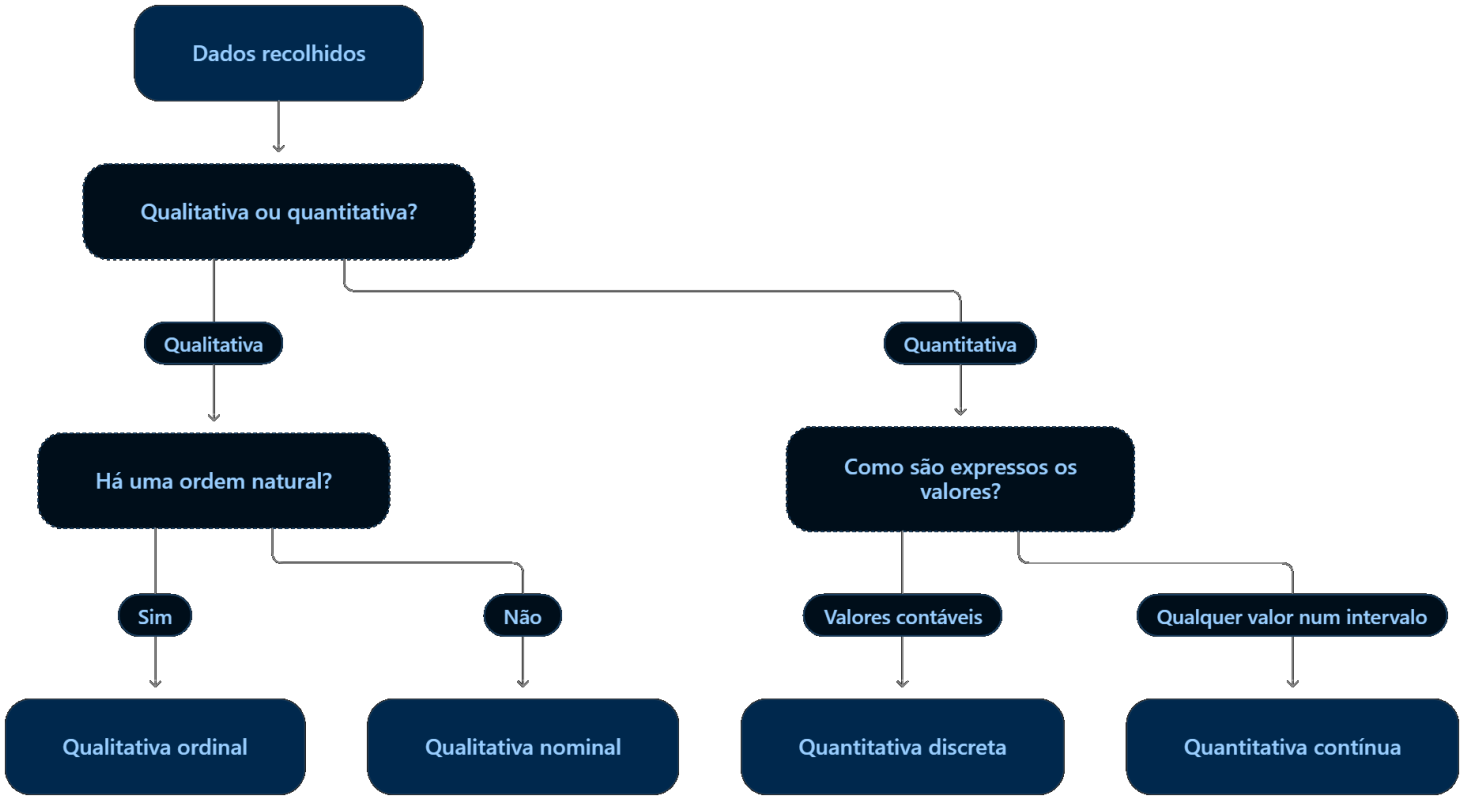
1.1 População, amostra e unidade estatística

Conceito	Definição	Exemplo
População	Conjunto de todos os elementos sobre os quais se quer obter informação.	Todos os estudantes do ISLA; todos os computadores de uma empresa; peças produzidas num mês.
Amostra	Subconjunto da população usado para obter informação sobre ela.	500 utilizadores de uma plataforma com 50 000 diversos.
Unidade estatística	Cada elemento individual da população que é observado.	Um estudante, um computador, um pedido, uma aplicação.
Atributo	Característica observada ou medida em cada unidade.	Idade, curso, n.º UC concluídas, sistema operativo, tempo de Internet.
Modalidade	Valores ou categorias que um atributo pode assumir.	SO = {Windows, Linux, macOS, Outro}.
Atenção: uma população não precisa ser constituída por pessoas (ex. computadores, pedidos, peças).		

1.2 Atributo e modalidades

Termo	O que é	Exemplo
Atributo	Característica observada/medida em cada unidade estatística.	idade; curso; n.º UC concluídas; SO; tempo diário de Internet.
Modalidades	Valores ou categorias que um atributo assume.	SO = {Windows, Linux, macOS, Outro}

1.3 Como classificar uma variável



Esquema — fluxo de classificação de uma variável (A) e escalas de medida crescente (B).

2. Variáveis e escalas de medida

2.1 Tipos de variável

Tipo	Subtipo	Característica	Exemplos
Qualitativa	Nominal	Sem ordem natural.	SO; linguagem preferida.
Qualitativa	Ordinal	Com ordem natural.	Grau de satisfação; qualidade de ligação.
Quantitativa	Discreta	Valores isolados, resultado de contagem.	N.º erros; n.º UC; n.º acessos.
Quantitativa	Contínua	Qualquer valor num intervalo, resultado de medição.	Tempo de execução; temperatura CPU; velocidade.
Regra prática: contar → geralmente discreta. Medir → geralmente contínua.			

2.2 Escalas de medida

Escala	Identificação	Ordenação	Diferenças	Zero absoluto	Razões
Nominal	✓				
Ordinal	✓	✓			
Intervalar	✓	✓	✓	—	—
Razão	✓	✓	✓	✓	✓
Importante: atribuir números a cores não torna a variável quantitativa (ex. códigos de SO codificados 1,2,3).					

2.3 Exercício de classificação

Variável	Tipo	Escala de medida
Sistema operativo utilizado	Qualitativa	Nominal
N.º de UC concluídas	Quantitativa discreta	Razão
Tempo diário de utilização do computador	Quantitativa contínua	Razão
Grau de satisfação com o curso	Qualitativa	Ordinal
Idade em anos completos	Quantitativa discreta	Razão
Temperatura máxima do processador	Quantitativa contínua	Intervalar
Resposta: os dois primeiros são qualitativo/quantitativo de acordo com o teste; n.º de UC e idade são discretas e de razão (zero absoluto).		

3. Frequências

3.1 As quatro frequências

Notação	Designação	Interpretação
F_i	Frequência absoluta	N.º de observações na modalidade/classe x_i.
$f_i = F_i/n$	Frequência relativa	Proporção das observações na modalidade/classe.
$F_a(x) = \Sigma_i F_i$	Frequência absoluta acumulada	N.º acumulado até à modalidade x_i.
$f_a(x) = F_a(x)/n$	Frequência relativa acumulada	Proporção acumulada até à modalidade x_i.

3.2 Exemplo resolvido — erros em 20 programas

x_i	F_i	f_i	F_a	f_a
0	3	0,15	3	0,15
1	6	0,30	9	0,45
2	6	0,30	15	0,75
3	3	0,15	18	0,90
4	2	0,10	20	1,00
Total	20	1,00	—	—

Leitura: $F_a(2)=15$ → 15 programas têm no máximo 2 erros. $f_a(2)=0,75$ → 75% dos programas.

Verificação: $\Sigma F=n$, $\Sigma f=1$, F e f são não decrescentes; no fim F=n e f=1. Nunca some as colunas F_a e f_a.

3.3 Exercício resolvido — dispositivos de 40 estudantes

x_i	F_i	f_i	F_a	f_a
1	4	0,10	4	0,10
2	10	0,25	14	0,35
3	14	0,35	28	0,70
4	8	0,20	36	0,90
5	4	0,10	40	1,00
Total	40	1,00	—	—

Qual a percentagem com, no máximo, 3 dispositivos? $f_a(3)=0,70 \rightarrow 70\%$.

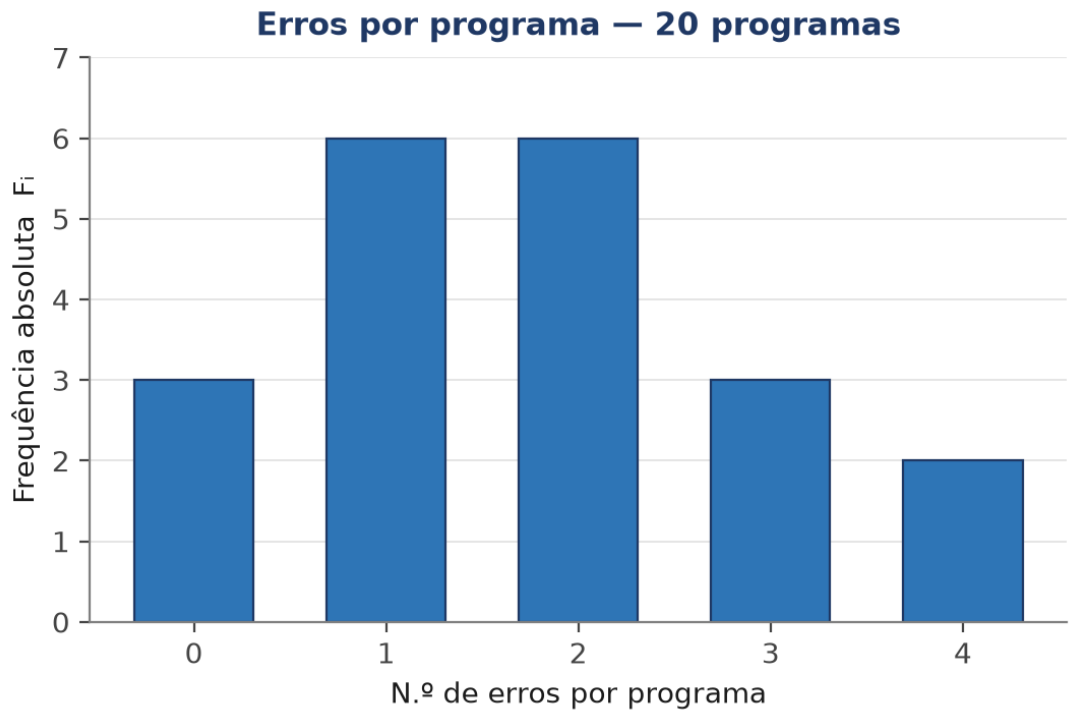
Qual a percentagem com mais de 3 dispositivos? $1 - 0,70 = 0,30 \rightarrow 30\%$.

4. Representações gráficas

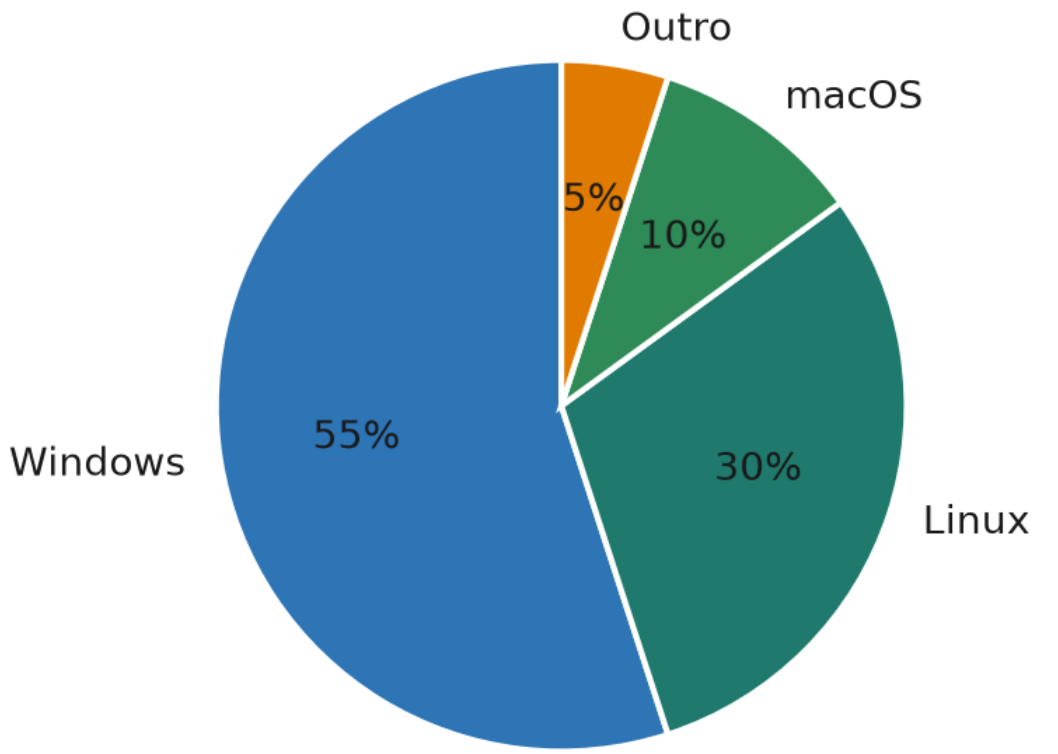
4.1 Escolha do gráfico

Tipo de dados	Representações adequadas
Qualitativos nominais	Barras, setores
Qualitativos ordinais	Barras ordenadas
Quantitativos discretos	Barras, pontos
Quantitativos contínuos agrupados	Histograma, polígono
Frequências acumuladas	Gráfico acumulado (ogiva)

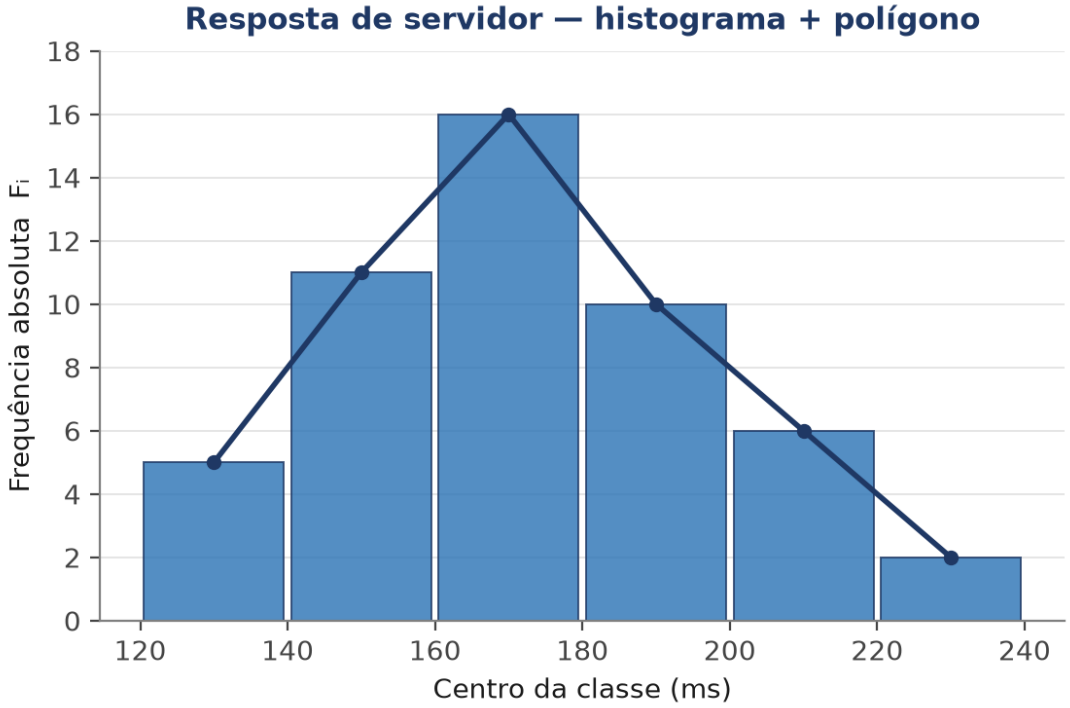
4.2 Exemplos gráficos



Barras — n.º de erros por programa (20 programas).



Setores — sistema operativo de 100 computadores (ângulo = 360° × f_i).



Histograma + polígono das respostas de um servidor.

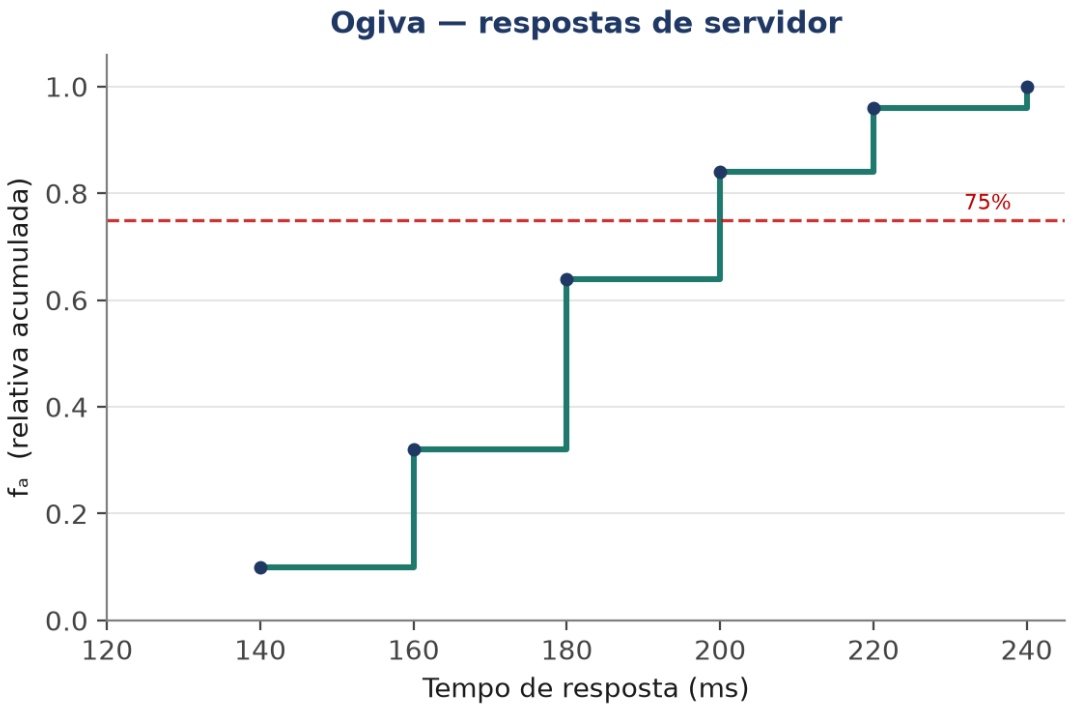
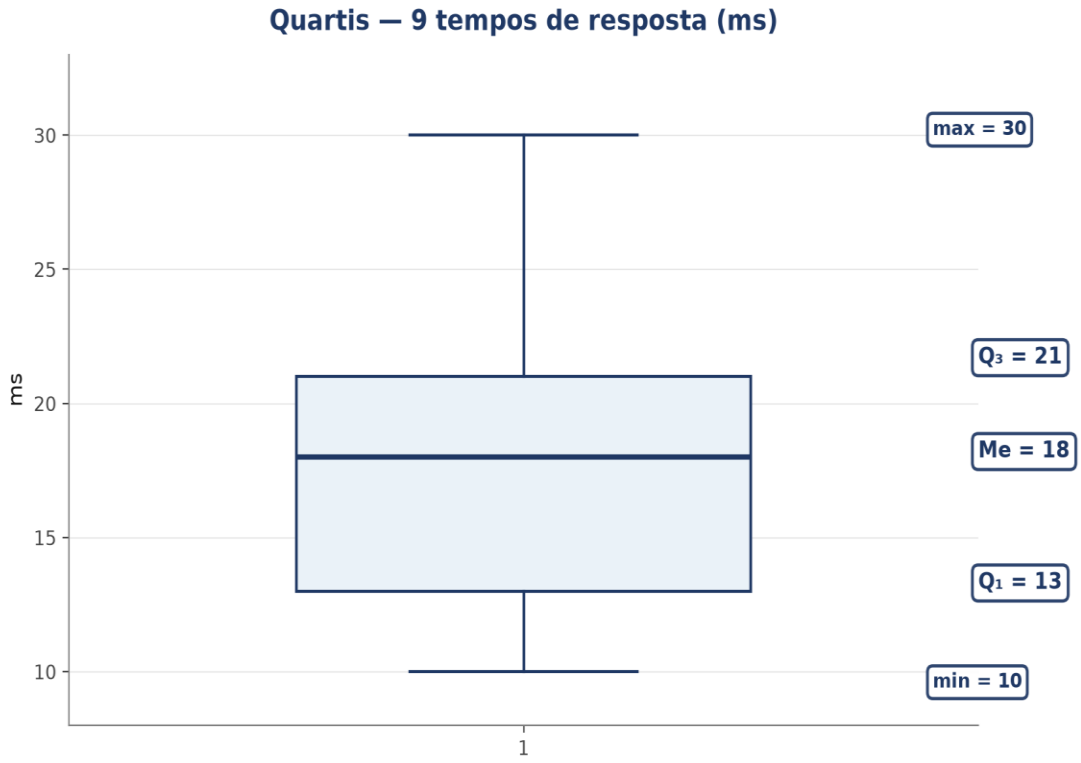
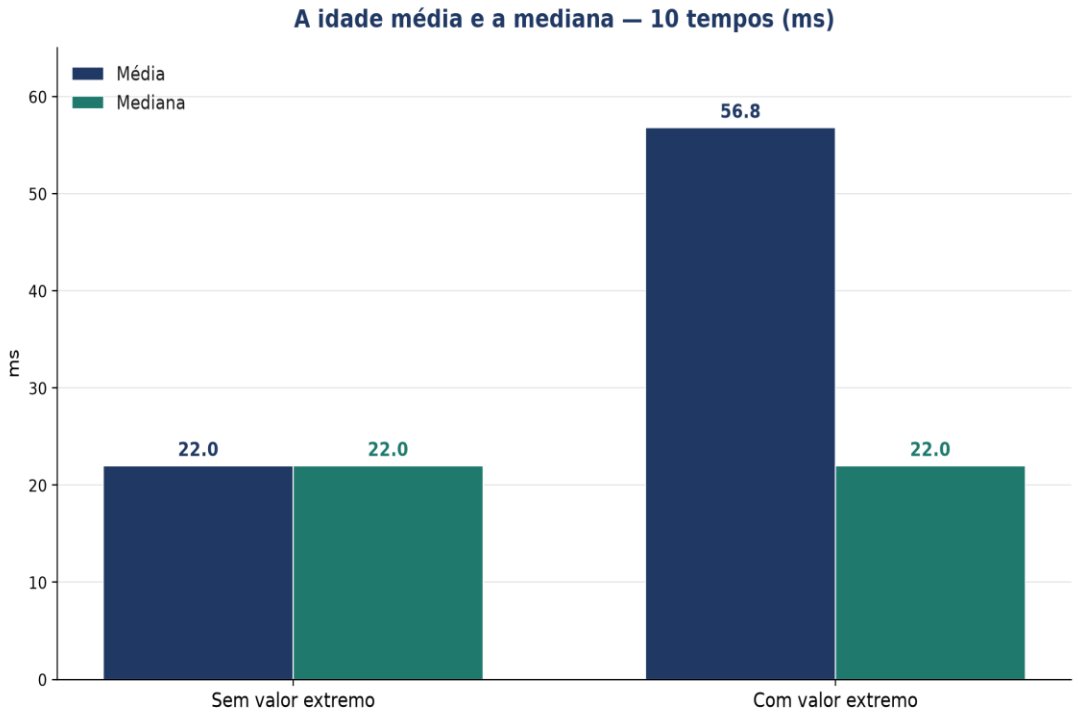


Gráfico acumulado (ogiva) — percentagens acumuladas.



Caixa de bigodes — quartis de 9 tempos (Q_1=13, Me=18, Q_3=21).



Comparação média vs mediana — influência de um valor extremo.

4.3 Cuidado com eixos enganadores

Um gráfico estatisticamente correto pode ficar visualmente enganador. Ex.: duas aplicações com médias 98 ms e 102 ms parecem magnas se o eixo vertical começa em 97 ms. Boa prática: escalas explicitadas, sem exageros.

4.4 Barras ou histograma?

Característica	Gráfico de barras	Histograma
Dados	Categorias ou valores discretos	Quantitativo contínuo agrupado
Barras	Separadas	Contíguas (intervalos adjacentes)
Ordem	Pode ser arbitrária (nominais)	Classes ordenadas numericamente
Largura	Não representa amplitude	A largura representa o intervalo
Erro frequente: um histograma não é um gráfico de barras sem espaços.		

5. Medidas de localização

5.1 As três medidas

Medida	Fórmula (resumo)	Vantagem	Limitação
Média aritmética	$\bar{x} = \Sigma x_j/n$ ou $\Sigma_i x_i F_i/n$	Usa todos os valores	Influenciada por valores extremos
Mediana	Posição central da amostra ordenada.	Resistente a extremos	Não usa distâncias entre valores
Moda	Valor de maior frequência F_i	Serve para qualitativas	Pode não ser única ou não informativa

5.2 Média aritmética

Dados individuais:

Dados (ms)	Cálculo	Resultado
18,20,22,24,26	(18+20+22+24+26)/5	$\bar{x}$ = 22 ms

Pela tabela de frequências:

Erros x_i	F_i	f_i	x_iF_i
0	2	0,20	0
1	5	0,50	5
2	3	0,30	6
Total	10	1,00	11

$\bar{x} = \Sigma_i\, x_iF_i \,/\, n = 11/10 = 1{,}1$ erros por programa.

5.3 Média ponderada

Critério	Nota	Peso
Usabilidade	16	30%
Segurança	14	50%
Documentação	18	20%

$\bar{x} = 0{,}30\cdot16 + 0{,}50\cdot14 + 0{,}20\cdot18 = 15{,}4$

5.4 Propriedades da média

- Soma dos desvios: $\Sigma x_j - \bar{x} = 0$ (desvios positivo e negativo compensam).
- Transformação linear: $y = a + bx \Rightarrow \bar{y} = a + b\cdot\bar{x}$ (somar 5 ms aumenta a média 5 ms; duplicar duplica).
- Mínimos quadrados: $\Sigma x_j - c$ descende até $c = \bar{x}$ (a média minimiza a soma dos quadrados dos desvios).

5.5 Mediana

Definição: valor que divide a amostra ordenada em duas partes iguais.

Cálculo: n ímpar → x_{(n+1)/2}; n par → média dos dois centrais x_{n/2} e x_{n/2+1}.

Dados	Cálculo	Mediana
3,5,7,9,12	n=5 → 3.º valor	Me = 7
3,5,7,9	n=4 → média de 2.º e 3.º	Me = (5+7)/2 = 6

Método com frequências acumuladas: n=10 → procuram-se as posições 5 e 6, que coincidem com x=1 ⇒ Me=1.

> A mediana é resistente a valores extremos: um pedido com latência anormalmente alta afecta pouco a ela.

5.6 Moda

Definição: valor ou modalidade de maior frequência absoluta.

Exemplo: 0,1,1,1,2,2,3 → Mo = 1.

Pode haver uma moda, várias modas ou nenhuma. Aplica-se a variáveis nominais.

5.7 Comparação das medidas

Medida	Vantagem	Limitação	Regra prática
Média	Usa todos os valores	Influenciada por extremos	Apresentar média e mediana em distribuições assimétricas
Mediana	Resistente; posição central	Não usa distâncias entre valores	Dados assimétricos ou ordinais
Moda	Serve para dados nominais	Pode não ser única	Quando se quer o valor mais comum

5.8 Exemplo — desempenho de um servidor

Medida	Cálculo	Valor
Média	(18+19+20+21+22+23+24+25+28+200)/10	40 ms
Mediana	(22+23)/2	22,5 ms

Média = 400/10 = 40 ms. Mediana = (22+23)/2 = 22,5 ms. A mediana descreve melhor o tempo habitual; um percentil elevado avalia os utilizadores mais afetados.

6. Quantis

6.1 Tipos e convenção

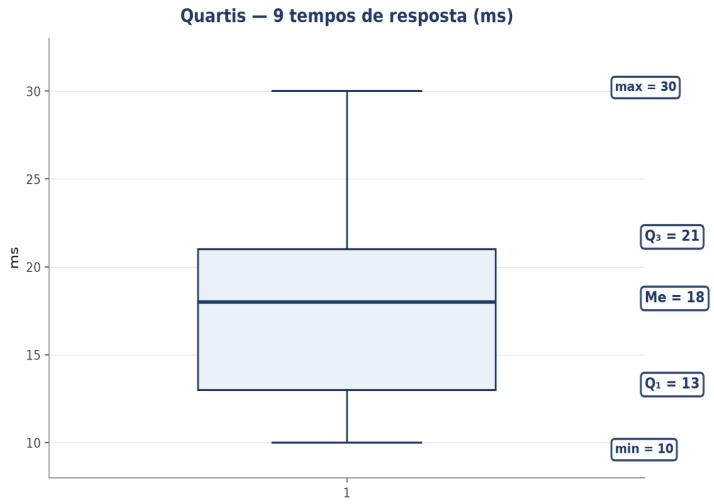
Quantil	Definição	Sagas
Quartis (Q_1, Q_2, Q_3)	25%, 50%, 75% da distribuição	$Q_2 = P_{50} = Me$
Decis (D_1...D_9)	10%, 20%, ..., 90%	
Percentis (P_1...P_{99})	1%, 2%, ..., 99%	P_{90} = limiar abaixo do qual estão ~90%

Convenção adotada (inversa da distribuição empírica): Q(p) = x_{⌈np⌉}, para 0<p≤1. Nota: para p=0,5 pode diferir da mediana quando n é par.

6.2 Quartis — exemplo

Dados (ms)	10	12	13	15	18	19	21	25	30	n=9
$Q_1 = Q(0,25) = x_3$	→ 13 ms									
$Q_2 = Q(0,50) = x_5$	→ 18 ms									
$Q_3 = Q(0,75) = x_7$	→ 21 ms									

Leitura: cerca de 75% das observações não excedem 21 ms.



Caixa de bigodes dos 9 tempos (ms): min=10, Q_1=13, Me=18, Q_3=21, max=30.

6.3 Percentil — exemplo com frequências acumuladas

Tempo (ms)	F_i	f_a
10	2	0,20
20	4	0,60
30	3	0,90
40	1	1,00
Total	10	1,00

$P_{75} = \min\{x : f_a(x) \geq 0,75\} = 30$ ms ($f_a(20)=0,60 < 0,75$; $f_a(30)=0,90 \geq 0,75$).

> Interpretação: pelo menos 75% das observações têm tempo de resposta não superior a 30 ms.

6.4 Estimativas para dados agrupados

Estimativa	Fórmula (classes)	Valor do exemplo
Média	$\bar{x} \approx \Sigma_i c_i F_i / n$	16 ms
Mediana	$Me \approx L + h \cdot (n/2 - F_a_ant)/F_med$	16 ms
3.º quartil Q_3	$Q_3 \approx L + h \cdot (np - F_a_ant)/F_classe$	21,67 ms

Exemplo: classes [0,10[, [10,20[, [20,30[(centros 5, 15, 25; F=2,5,3, n=10). Média ≈ (5·2+15·5+25·3)/10 = 16 ms.

6.5 Precaução

A média por centros de classe e os quantis por interpolação são estimativas, não os valores exatos dos dados originais. Classes muito largas podem esconder assimetrias e extremos; as estimativas dependem da organização das classes. Conservar os dados individuais sempre que possível.

7. Escolha da medida adequada

Situação	Medida(s) recomendada(s)
Variável nominal	Moda
Variável ordinal	Mediana (como categoria) e moda
Quantitativo aproximadamente simétrico	Média e mediana
Quantitativo com valores extremos	Mediana e quantis; complementar com média
Avaliação de níveis de serviço	Mediana e percentis elevados