Estatística – Engenharia Informática

Aula 3 – Ficha de Exercícios

Distribuições de Frequências e Representações Gráficas

ISLA Santarém - Instituto Politécnico

Parte II – Exercícios

Exercício 1 – Conceitos fundamentais

Numa turma de 40 estudantes registou-se a linguagem de programação preferida. Obtiveram-se os resultados: 14 preferem Python, 10 Java, 8 C#, 5 JavaScript e 3 C++.

a) Identifique a variável em estudo e classifique-a.

b) Construa uma tabela com as modalidades, F_i e f_i.

c) Verifique as propriedades fundamentais das frequências.

d) Faz sentido calcular F_a e f_a neste caso? Justifique.

e) Qual a representação gráfica mais adequada? Indique pelo menos uma opção.

Exercício 2 – Da lista de dados à tabela de frequências

Durante 20 execuções de um programa registou-se o número de erros detetados:

$$2, 1, 0, 3, 2, 1, 4, 2, 0, 1, 2, 3, 1, 0, 2, 4, 1, 2, 3, 2.$$

a) Organize os dados por ordem crescente.

b) Construa a tabela de distribuição de frequências contendo F_i, f_i, F_a e f_a.

c) Determine a percentagem de execuções sem erros.

d) Determine a percentagem de execuções com, no máximo, 2 erros.

e) Quantas execuções apresentaram mais de 2 erros?

Exercício 3 – Completar uma tabela

O número de pedidos simultâneos recebidos por um pequeno servidor foi observado em 50 instantes. Complete a tabela.

Pedidos x_i	F_i	f_i	F_a	f_a
0	5			
1	10			
2	15			0,60
3		0,24		
4	8			

Responda ainda:

a) Qual a percentagem de instantes com pelo menos 3 pedidos simultâneos?

b) Qual a percentagem de instantes com menos de 2 pedidos?

Exercício 4 – Frequências acumuladas e interpretação

A tabela seguinte apresenta parcialmente a distribuição do número de incidentes de segurança registados por dia durante 30 dias.

x_i	0	1	2	3	4
F_a	6	15	23	28	30

a) Determine F_i para cada valor de x_i.

b) Determine f_i e f_a.

c) Em quantos dias se registaram, no máximo, 2 incidentes?

d) Qual a percentagem de dias com mais de 1 incidente?

Exercício 5 – Dados contínuos agrupados em classes

Os tempos de resposta, em milissegundos, de 24 pedidos a uma API foram:

$$42, 47, 51, 55, 58, 61, 63, 66, 68, 71, 73, 75, 78, 81, 84, 87, 90, 94, 97, 102, 108, 112, 118, 124.$$

Considere as classes

$$[40, 60[,\ [60, 80[,\ [80, 100[,\ [100, 120[,\ [120, 140[.$$

a) Determine a amplitude total dos dados.

b) Indique a amplitude de cada classe.

c) Construa uma tabela com classe, centro de classe, F_i, f_i, F_a e f_a.

d) Que percentagem dos pedidos teve tempo de resposta inferior a 100 ms?

e) Que percentagem apresentou tempo de resposta igual ou superior a 80 ms?

Exercício 6 – Escolha do número de classes

Uma aplicação produziu $n = 120$ observações de tempo de processamento, com mínimo 12,4 ms e máximo 89,6 ms.

a) Use a regra de Sturges, $k \approx 1 + 3,322 \log_{10}(n)$, para sugerir um número de classes.

b) Determine a amplitude total.

c) Sugira uma amplitude de classe conveniente.

d) Proponha intervalos de classe que cubram todos os dados.

e) Explique por que razão a regra de Sturges deve ser entendida como orientação e não como obrigação.

Exercício 7 – Escolher o gráfico adequado

Para cada situação, indique uma representação gráfica adequada e justifique brevemente.

a) Sistema operativo utilizado por 500 estudantes.

b) Número de falhas por dia durante um mês.

c) Tempos de resposta de 2 000 pedidos, agrupados em classes.

d) Percentagem acumulada de pedidos com tempo de resposta até determinado limite.

e) Distribuição dos níveis de satisfação: Muito insatisfeito, Insatisfeito, Neutro, Satisfeito, Muito satisfeito.

Indique também em quais das situações um histograma seria inadequado.

Exercício 8 – Barras ou histograma?

Um estudante representou a variável "número de erros por execução", com valores 0, 1, 2, 3 e 4, através de cinco retângulos contíguos, sem qualquer espaço entre eles. Outro estudante representou os tempos de resposta agrupados em $[0, 10[$, $[10, 20[$, $[20, 30[$ através de barras separadas.

a) Comente criticamente as duas representações.

b) Explique a diferença conceptual entre um gráfico de barras e um histograma.

c) Se as classes de um histograma tiverem amplitudes diferentes, é suficiente usar F_i como altura dos retângulos? Justifique.

Exercício 9 – Leitura crítica de uma apresentação de dados

Uma empresa compara o número mensal de falhas de dois sistemas: Sistema A = 98 falhas e Sistema B = 102 falhas. Num gráfico de barras, o eixo vertical começa em 95 e termina em 103.

a) Qual é a diferença absoluta e relativa entre os dois valores? Use o Sistema A como referência na diferença relativa.

b) Por que razão o gráfico pode criar uma impressão visual exagerada da diferença?

c) Como apresentaria os dados de forma mais transparente?

d) É sempre errado truncar um eixo? Discuta brevemente.

Exercício 10 – Problema integrador: desempenho de uma rede

O número de interrupções de ligação registado em 30 sessões foi:

$$0, 1, 0, 2, 1, 3, 0, 1, 2, 0, 4, 1, 1, 2, 0, 3, 2, 1, 0, 1, 2, 4, 0, 1, 3, 2, 1, 0, 2, 1.$$

a) Identifique e classifique a variável.

b) Construa a distribuição de frequências completa com F_i, f_i, F_a e f_a.

c) Determine a percentagem de sessões com, no máximo, uma interrupção.

d) Determine a percentagem com pelo menos duas interrupções.

e) Represente a distribuição através de um gráfico adequado.

f) Um colega propõe um histograma. Considera essa a melhor escolha? Justifique.

g) Escreva duas conclusões objetivas que possam ser retiradas da distribuição, sem recorrer ainda a medidas de tendência central.

Parte II – Resoluções

Resolução – Exercício 1

a) Variável: linguagem de programação preferida. É **qualitativa nominal**.

b) Como $n = 40$, $f_i = F_i/40$:

Linguagem	F_i	f_i
Python	14	0,350
Java	10	0,250
C#	8	0,200
JavaScript	5	0,125
C++	3	0,075
Total	40	1,000

c) Verifica-se $\sum F_i = 40 = n$ e $\sum f_i = 1$ (100%).

d) Não existe uma ordem natural entre as linguagens. Por isso, frequências acumuladas dependeriam de uma ordenação arbitrária e não têm interpretação estatística útil.

e) Um **gráfico de barras** é particularmente adequado; também pode usar-se um gráfico de setores se o objetivo for salientar a composição do total.

Resolução – Exercício 2

Ordenação:

$$0, 0, 0, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 4, 4.$$

A tabela é:

x_i	F_i	f_i	F_a	f_a
0	3	0,15	3	0,15
1	5	0,25	8	0,40
2	7	0,35	15	0,75
3	3	0,15	18	0,90
4	2	0,10	20	1,00
Total	20	1,00		

Sem erros: $3/20 = 15\%$. No máximo 2 erros: $f_a(2) = 0,75 = 75\%$. Mais de 2 erros: $3 + 2 = 5$ execuções, ou 25%.

Resolução – Exercício 3

Como $n = 50$, para $x = 3$: $F_i = 0,24 \times 50 = 12$. Assim:

x_i	F_i	f_i	F_a	f_a
0	5	0,10	5	0,10
1	10	0,20	15	0,30
2	15	0,30	30	0,60
3	12	0,24	42	0,84
4	8	0,16	50	1,00

a) Pelo menos 3 pedidos: $(12+8)/50 = 0,40$, isto é, **40%**.

b) Menos de 2 pedidos: $(5+10)/50 = 0,30$, isto é, **30%**.

Resolução – Exercício 4

As frequências absolutas simples obtêm-se por diferenças sucessivas das acumuladas:

$$6, \quad 15-6=9, \quad 23-15=8, \quad 28-23=5, \quad 30-28=2.$$

x_i	F_i	f_i	F_a	f_a
0	6	0,200	6	0,200
1	9	0,300	15	0,500
2	8	0,267	23	0,767
3	5	0,167	28	0,933
4	2	0,067	30	1,000

(Valores relativos arredondados a três casas decimais.) No máximo 2 incidentes: 23 dias. Mais de 1 incidente: $30-15=15$ dias, isto é, **50%**.

Resolução – Exercício 5

a) Amplitude total: $124-42=82$ ms.

b) Cada classe tem amplitude 20 ms.

Contagens: 5, 8, 6, 4 e 1. Logo:

Classe	Centro	F_i	f_i	F_a	f_a
$[40,60[$	50	5	0,2083	5	0,2083
$[60,80[$	70	8	0,3333	13	0,5417
$[80,100[$	90	6	0,2500	19	0,7917
$[100,120[$	110	4	0,1667	23	0,9583
$[120,140[$	130	1	0,0417	24	1,0000

Inferior a 100 ms: $19/24 \approx 79,17\%$. Igual ou superior a 80 ms: $11/24 \approx 45,83\%$.

Resolução – Exercício 6

a) $k \approx 1+3,322\log_{10}(120) \approx 7,91$. Uma escolha razoável é **8 classes**.

b) $A = 89,6-12,4 = 77,2$ ms.

c) $A/k \approx 77,2/8 = 9,65$ ms. É conveniente usar amplitude **10 ms**.

d) Por exemplo: $[10,20[, [20,30[, \ldots, [80,90]$. A última classe é fechada à direita para incluir 89,6.

e) Sturges é uma regra heurística. A escolha deve considerar dimensão da amostra, forma da distribuição, resolução dos dados e finalidade da análise. Diferentes amplitudes podem revelar ou esconder padrões.

Resolução – Exercício 7

a) Sistema operativo: gráfico de barras (ou setores). Variável qualitativa nominal.

b) Falhas por dia: gráfico de barras para a distribuição das contagens; se o objetivo for mostrar evolução temporal, um gráfico de linhas por dia também pode ser informativo.

c) Tempos agrupados em classes: **histograma**.

d) Percentagem acumulada: **ogiva** (curva de frequências acumuladas).

e) Satisfação: barras ordenadas segundo a ordem natural das categorias.

O histograma é inadequado para a) e e), e não é a representação natural de b) quando se representam valores discretos individuais.

Resolução – Exercício 8

a) Para "número de erros", variável quantitativa discreta, um gráfico de barras com separação entre barras comunica melhor que os valores são isolados. Para tempos contínuos agrupados em classes, as barras do histograma devem ser contíguas, pois representam intervalos adjacentes.

b) No gráfico de barras, cada barra representa uma categoria ou valor discreto. No histograma, cada retângulo representa um **intervalo** de valores de uma variável quantitativa contínua; a área do retângulo representa frequência.

c) Não necessariamente. Com amplitudes diferentes, deve usar-se **densidade de frequência** na altura, por exemplo F_i/h_i, de modo que a área seja proporcional à frequência.

Resolução – Exercício 9

a) Diferença absoluta: $102 - 98 = 4$ falhas. Diferença relativa, tomando A como referência: $4/98 \times 100 \approx 4,08\%$.

b) Um eixo de 95 a 103 faz com que uma diferença de apenas 4 unidades ocupe metade da escala visível, amplificando a impressão visual.

c) Num gráfico de barras, uma solução transparente é iniciar o eixo em zero; também se podem apresentar diretamente os valores e a diferença relativa.

d) Não. Em gráficos de linhas ou quando se pretende analisar pequenas variações em torno de um nível elevado, um eixo truncado pode ser útil, desde que esteja claramente assinalado e não induza o leitor em erro. Em barras, o zero é especialmente importante porque o comprimento da barra codifica magnitude.

Resolução – Exercício 10

A variável é o número de interrupções por sessão: **quantitativa discreta**, em escala de razão. As contagens são $8, 10, 7, 3, 2$ para 0,1,2,3,4 interrupções, respetivamente.

x_i	F_i	f_i	F_a	f_a
0	8	0,2667	8	0,2667
1	10	0,3333	18	0,6000
2	7	0,2333	25	0,8333
3	3	0,1000	28	0,9333
4	2	0,0667	30	1,0000

c) No máximo uma interrupção: $18/30 = 60\%$.

d) Pelo menos duas interrupções: $(7 + 3 + 2)/30 = 40\%$.

e) Um gráfico de barras é adequado, com x_i no eixo horizontal e F_i (ou f_i) no vertical.

f) O histograma não é a melhor escolha porque a variável é discreta e assume valores isolados. As barras separadas tornam essa natureza explícita.

g) Exemplos de conclusões: (i) 60% das sessões apresentam no máximo uma interrupção; (ii) apenas $5/30 \approx 16,7\%$ apresentam três ou mais interrupções.