LICENCIATURA EM ENGENHARIA INFORMÁTICA

Estatística — Resumo visual

Reorganização por conceito dos diapositivos das aulas 2, 3 e 4 (87 slides), com gráficos, tabelas e exemplos resolvidos passo a passo. Todos os dados e resultados são os do documento original.

COMO ESTE RESUMO ESTÁ ORGANIZADO

1. A linguagem da Estatística
2. Do dado bruto à tabela de frequências
3. Ver os dados: que gráfico escolher
4. Resumir com um número
5. Quando só temos classes
6. Escolher e comunicar
7. Erros frequentes e verificação rápida

ONDE ESTÁ CADA TEMA NOS SLIDES

Tabela 1 correspondência entre a nova organização e o documento original

Parte deste resumo	Slides	Aula
A linguagem da Estatística	1 – 25	aula2
Do dado bruto à tabela	26 – 42	aula3
Ver os dados	43 – 53	aula3
Resumir com um número	54 – 77	aula4
Quando só temos classes	78 – 82	aula4
Escolher e comunicar	83 – 87	aula4

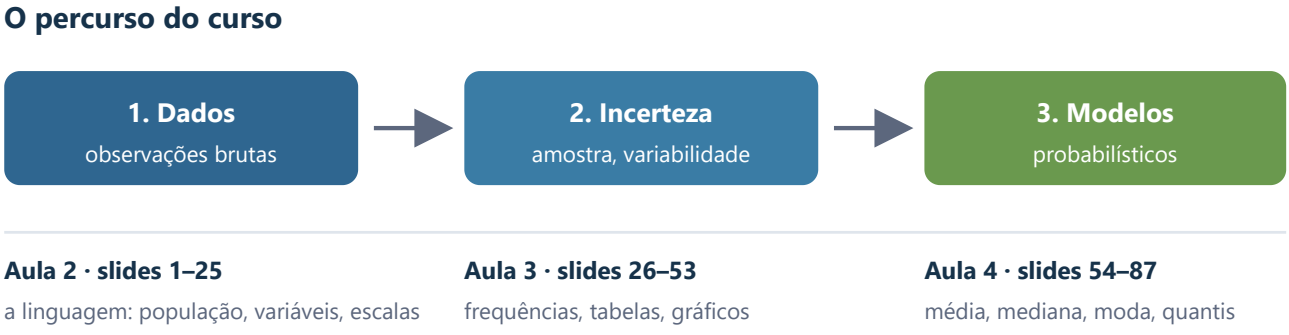


Figura 1 O fio condutor: os dados brutos são organizados, a incerteza é quantificada e o resultado é um modelo — ou uma decisão.

Parte 1 A linguagem da Estatística

A Estatística é um **conjunto de métodos para recolher, organizar, apresentar, analisar e interpretar dados**. Antes de calcular seja o que for, é preciso saber *o que* estamos a observar e *como* o podemos medir. Toda esta parte serve para responder a três perguntas: quem observo, o que observo, e que operações fazem sentido com o que observei.

1.1 Quem observo: população, unidade estatística e amostra

Tabela 2 os três conceitos no exemplo de 50 000 utilizadores e 500 selecionados

Conceito	Definição	No exemplo dos utilizadores
População	Conjunto de *todos* os elementos sobre os quais se pretende obter informação	os 50 000 utilizadores ativos
Unidade estatística	Cada elemento individual da população sobre o qual são observadas características	um utilizador
Amostra	Subconjunto da população usado para obter informação sobre ela	os 500 utilizadores selecionados

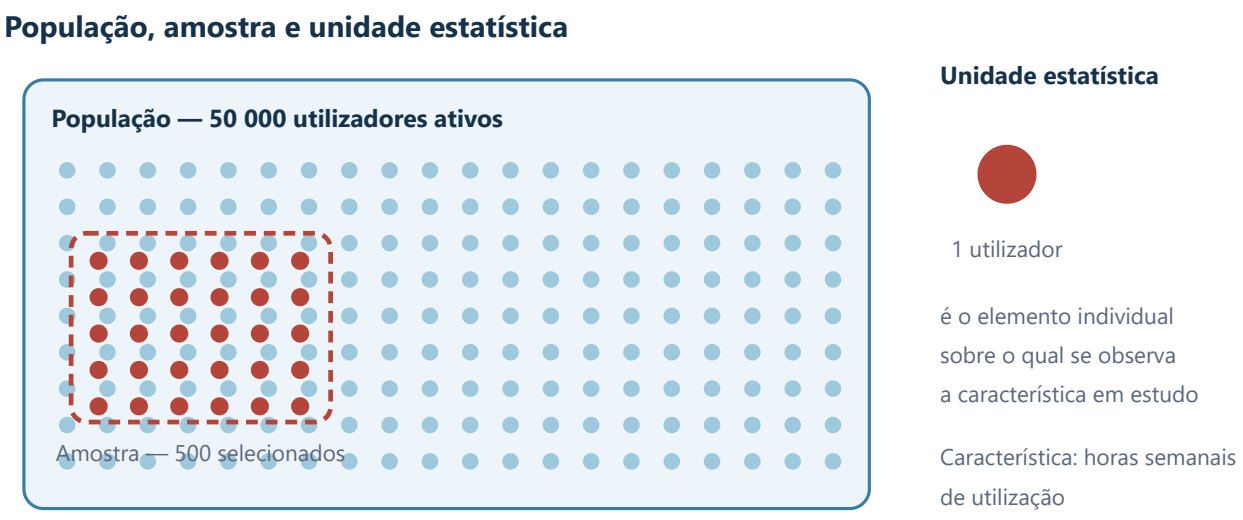


Figura 2 Uma população não tem de ser feita de pessoas: pode ser de computadores, de pedidos a um servidor ou de peças produzidas numa fábrica.

> **Ideia central:** só é possível retirar conclusões válidas sobre a população se a amostra for *adequadamente selecionada*. A qualidade da conclusão depende da qualidade da seleção.

1.2 O que observo: atributos e modalidades

Tabela 3 atributo é a pergunta; modalidades são as respostas possíveis

Termo	Definição	Exemplos
Atributo	característica observada ou medida em cada unidade estatística	idade · curso · nº de UC concluídas · sistema operativo · tempo diário de utilização
Modalidade	cada valor ou categoria que o atributo pode assumir	Sistema operativo = { Windows, Linux, macOS, Outro }

1.3 Que tipo de variável é

A distinção fundamental é entre **qualidade** e **quantidade**. Dentro de cada uma há dois subtipos, e o subtipo determina tudo o que se pode calcular depois.

Tabela 4 classificação das variáveis estatísticas

Tipo	Subtipo	Critério	Exemplos
Qualitativa	Nominal	categorias *sem* ordem natural	sistema operativo, linguagem preferida
	Ordinal	categorias *com* ordem natural	satisfação, qualidade da ligação
Quantitativa	Discreta	valores isolados, resultantes de uma *contagem*	nº de erros, nº de acessos, nº de mensagens
	Contínua	qualquer valor num intervalo, resultante de uma *medição*	tempo de execução, temperatura do CPU, velocidade de transmissão

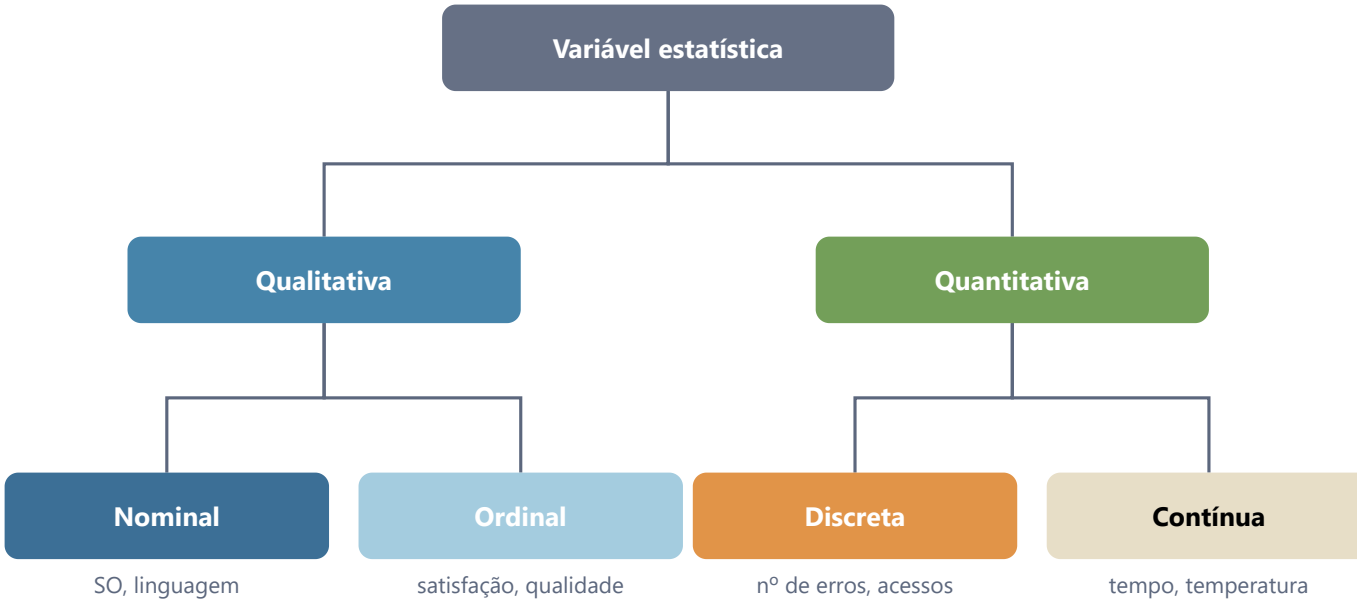


Figura 3 Regra prática: **contar** dá geralmente uma variável discreta; **medir** dá geralmente uma variável contínua.

> **ERRO FREQUENTE**
>
> Atribuir números a categorias **não** transforma uma variável qualitativa em quantitativa. Codificar cores como 1, 2 e 3 continua a ser uma variável nominal — e a média desses códigos não tem qualquer interpretação.

1.4 Até onde posso ir: escalas de medida

A escala determina que operações matemáticas fazem sentido, que medidas estatísticas são adequadas e que representações gráficas são legítimas.

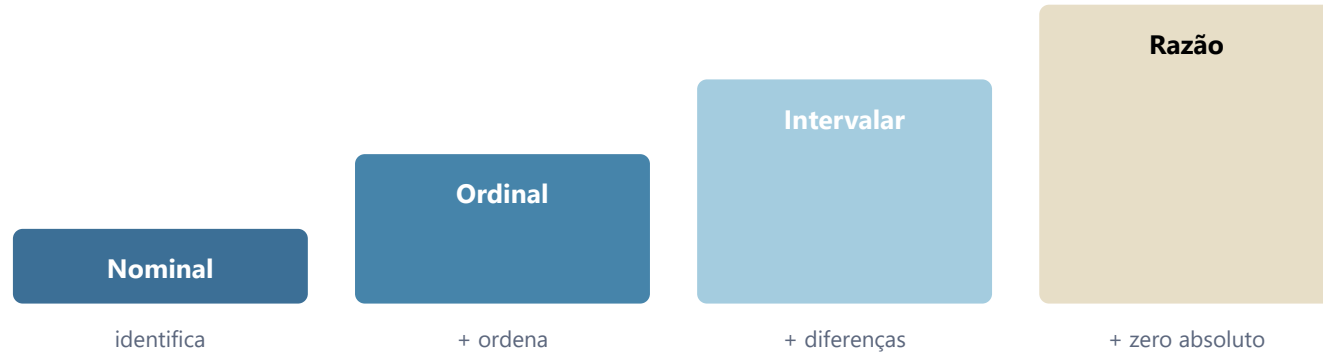


Figura 4 A progressão Nominal → Ordinal → Intervalar → Razão é cumulativa: cada degrau herda o anterior e acrescenta poder.

Tabela 5 matriz de propriedades das quatro escalas

Escala	Identificação	Ordenação	Diferenças	Zero absoluto	Razões	Exemplo
Nominal	✓	—	—	—	—	Windows, Linux, macOS
Ordinal	✓	✓	—	—	—	Mau < Razoável < Bom
Intervalar	✓	✓	✓	—	—	temperatura em °C
Razão	✓	✓	✓	✓	✓	tempo, tamanho de ficheiro, memória

> **Intervalar vs razão:** em °C, 20° não é "o dobro do calor" de 10° — o zero é convencional. Em ms, 20 ms *é* o dobro de 10 ms — o zero é ausência absoluta. É por isso que só na escala de razão as razões têm significado.

EXEMPLO RESOLVIDO — CLASSIFICAR SEIS VARIÁVEIS

Para cada variável, identificar o *tipo* e a *escala*.

Tabela 6 classificação das seis variáveis: tipo e escala de medida

Variável	Tipo	Escala	Porquê
Sistema operativo	Qualitativa nominal	Nominal	categorias sem ordem
UC concluídas	Quantitativa discreta	Razão	contagem; 0 = nenhuma
Tempo de utilização	Quantitativa contínua	Razão	medição; 0 = ausência
Satisfação	Qualitativa ordinal	Ordinal	há ordem, distâncias não mensuráveis
Idade (anos completos)	Quantitativa discreta	Razão	contagem de anos completos
Temperatura do CPU (°C)	Quantitativa contínua	Intervalar	0 °C não é ausência de temperatura

CASO PARA PENSAR — A ESCALA DE 1 A 5

«Classifique o desempenho da aplicação de 1 a 5», com 1 = Muito mau e 5 = Excelente.

- É **qualitativa ordinal** — há ordem entre as categorias.
- A escala é **ordinal**.
- **Não** podemos garantir que a diferença entre 1 e 2 equivale à diferença entre 4 e 5: as distâncias não são mensuráveis.

Parte 2 Do dado bruto à tabela de frequências

Uma lista de observações já contém informação, mas é a **organização** que torna visível a sua estrutura. A tabela de frequências é o primeiro instrumento de análise.

2.1 As quatro frequências

Tabela 7 as quatro frequências e as suas relações

Notação	Designação	Interpretação	Fórmula
F_i	Frequência absoluta	número de observações na modalidade/classe	F_i
f_i	Frequência relativa	proporção na modalidade/classe	F_i / n
F_a	Frequência absoluta acumulada	número acumulado até à modalidade	$\Sigma_{j \le i} F_j$
f_a	Frequência relativa acumulada	proporção acumulada até à modalidade	F_a / n

$$\Sigma F_i = \mathrm{n} \quad \cdot \quad \Sigma f_i = 1 \quad \cdot \quad f_i = F_i/\mathrm{n} \quad \cdot \quad f_a = F_a/\mathrm{n}$$

No último valor da distribuição: $F_a = n$ e $f_a = 1$ (100%)

F_i e f_i descrevem **uma modalidade**; F_a e f_a descrevem **o que foi acumulado até essa modalidade**.

2.2 Exemplo completo: 20 programas, 20 contagens de erros

DADOS BRUTOS

Número de erros encontrados em 20 programas durante um teste:

```
2, 1, 0, 3, 2, 1, 4, 2, 0, 1, 2, 3, 1, 2, 0, 4, 1, 2, 3, 1
```

Perguntas naturais: qual o número de erros mais frequente? Que proporção dos programas tem no máximo 2 erros? Quantos programas têm menos de 3 erros?

Passo 1. Contar quantas vezes aparece cada valor → F_i. **Passo 2.** Dividir por n = 20 → f_i. **Passo 3.** Acumular → F_a e f_a.

Tabela 8 tabela de frequências completa dos 20 programas

x_i (erros)	F_i	f_i	F_a	f_a
0	3	0,15	3	0,15
1	6	0,30	9	0,45
2	6	0,30	15	0,75
3	3	0,15	18	0,90
4	2	0,10	20	1,00
Total	**20**	**1,00**	—	—

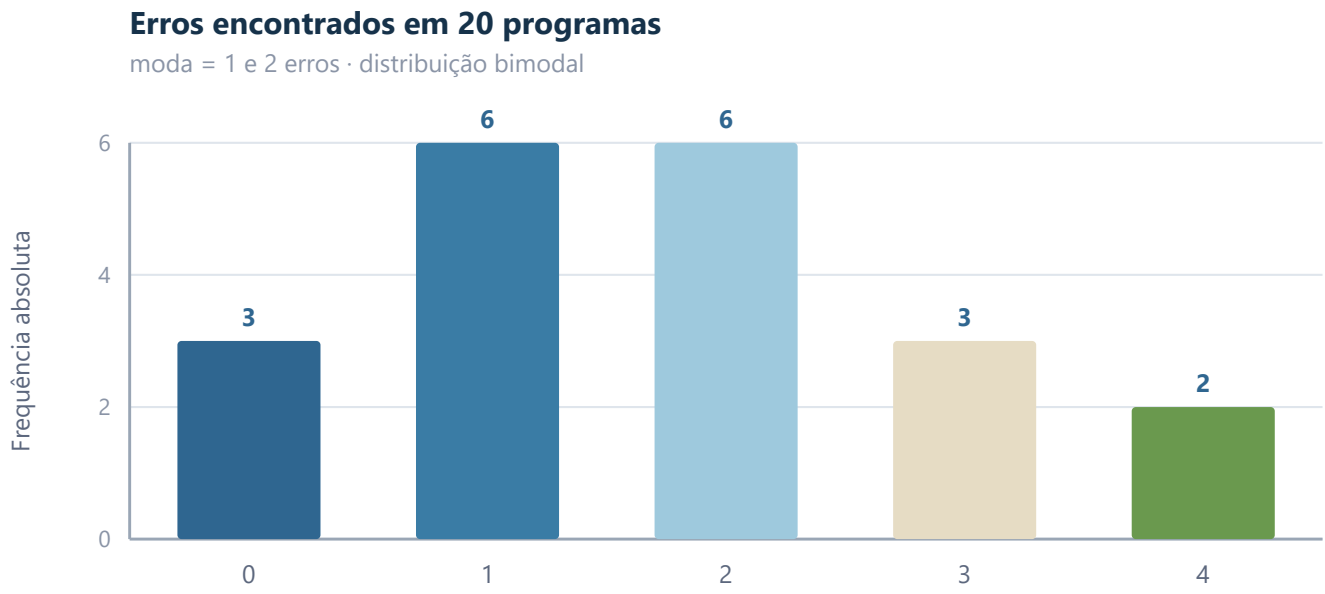


Figura 5 Leitura direta: $F_a(2) = 15 \rightarrow$ 15 programas têm no máximo 2 erros; $f_a(2) = 0{,}75 \rightarrow$ 75%.

Da mesma tabela sai a média: $\Sigma\, x_i F_i = 35$ com $n = 20 \rightarrow \bar{x} = 35/20 =$ **1,75 erros por programa**.

PORQUE NÃO HÁ «TOTAL» NA COLUNA F_A

Somar frequências acumuladas não tem interpretação útil. Uma tabela bem construída tem de satisfazer: $\Sigma F_i = n$, $\Sigma f_i = 1$, e F_a e f_a **não podem decrescer**.

2.3 A tabela muda com o tipo de variável

NOMINAL — SEM ACUMULADAS

Tabela 9 100 computadores

Sistema operativo	F_i	f_i
Windows	55	0,55
Linux	30	0,30
macOS	10	0,10
Outro	5	0,05
Total	**100**	**1,00**

ORDINAL — ACUMULADAS FAZEM SENTIDO

Tabela 10 80 utilizadores

Qualidade	F_i	f_i	F_a
Má	8	0,10	8
Razoável	20	0,25	28
Boa	36	0,45	64
Muito boa	16	0,20	80

> **Porque é que «Windows + Linux» não tem significado, mas «Má + Razoável» tem?** Porque acumular exige uma ordem natural. Sem ordem, a soma de categorias é arbitrária — depende da ordem em que as escrevemos. Com ordem, a acumulação tem um sentido claro: «até este nível de qualidade».

DISCRETA — CADA VALOR OBSERVADO É UMA MODALIDADE

Tabela 11 falhas diárias de um serviço, em 30 dias

x_i (falhas)	F_i	f_i	F_a	f_a
0	12	0,40	12	0,40
1	9	0,30	21	0,70
2	6	0,20	27	0,90
3	3	0,10	30	1,00

Parte 3 Ver os dados: que gráfico escolher

O gráfico não serve para «ficar bonito» — serve para respeitar a natureza da variável e facilitar a leitura. A escolha está praticamente determinada pelo tipo de dados.

Tabela 12 que representação usar para que dados

Tipo de dados	Representações adequadas	Porquê
Qualitativos nominais	Barras, setores	não há ordem a respeitar
Qualitativos ordinais	Barras ordenadas	a ordem das categorias tem significado
Quantitativos discretos	Barras, pontos	cada valor é uma modalidade isolada
Quantitativos contínuos agrupados	Histograma, polígono	as classes são intervalos adjacentes
Frequências acumuladas	Gráfico acumulado (ogiva)	mostra proporções «até x»

3.1 Barras — categorias e valores isolados

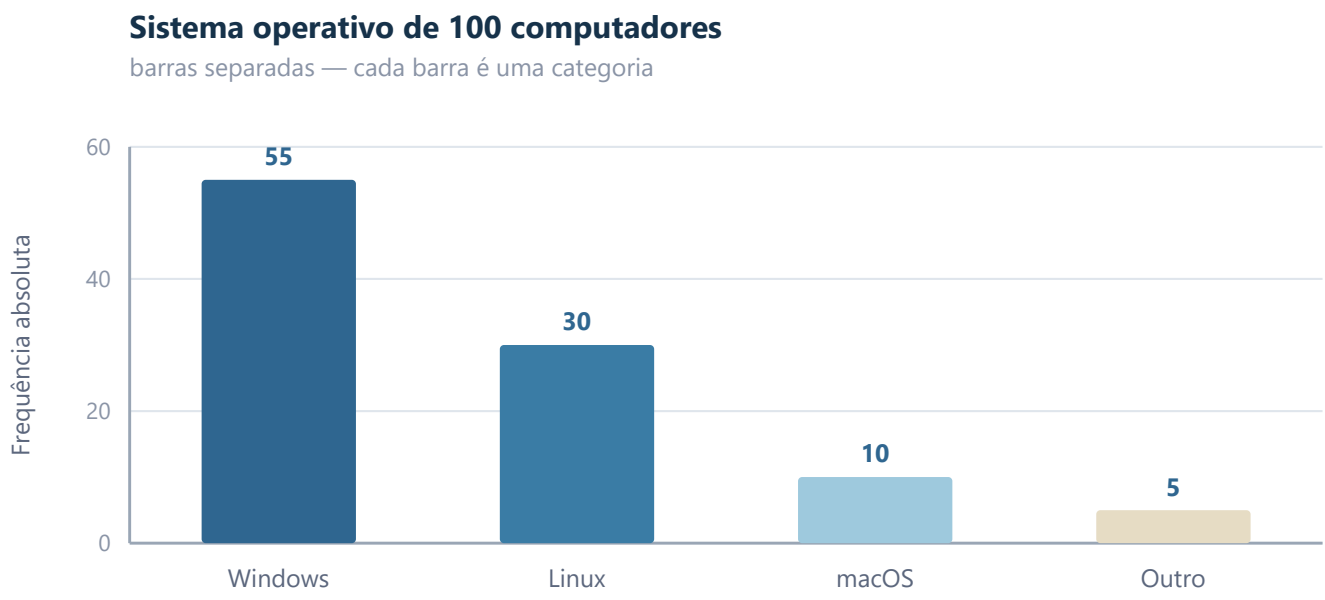


Figura 6 As barras estão **separadas**: cada barra representa uma categoria distinta e a ordem pode ser arbitrária (dados nominais).

3.2 Setores — composição de um total

Útil com poucas categorias. O ângulo de cada setor é $\alpha_i = 360° \times f_i$.

$$\alpha_i = 360° \times f_i$$

Exemplo: Linux representa 30% → $\alpha = 360° \times 0{,}30 = 108°$

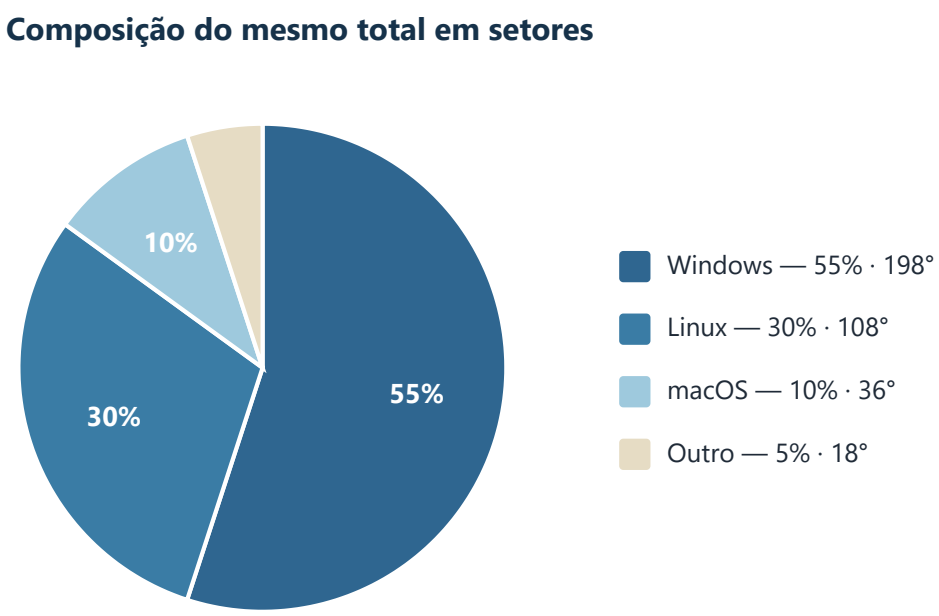


Figura 7 Com muitas categorias ou proporções semelhantes a comparação visual torna-se difícil — nesses casos as barras são normalmente superiores.

3.3 Barras ordenadas — variáveis ordinais

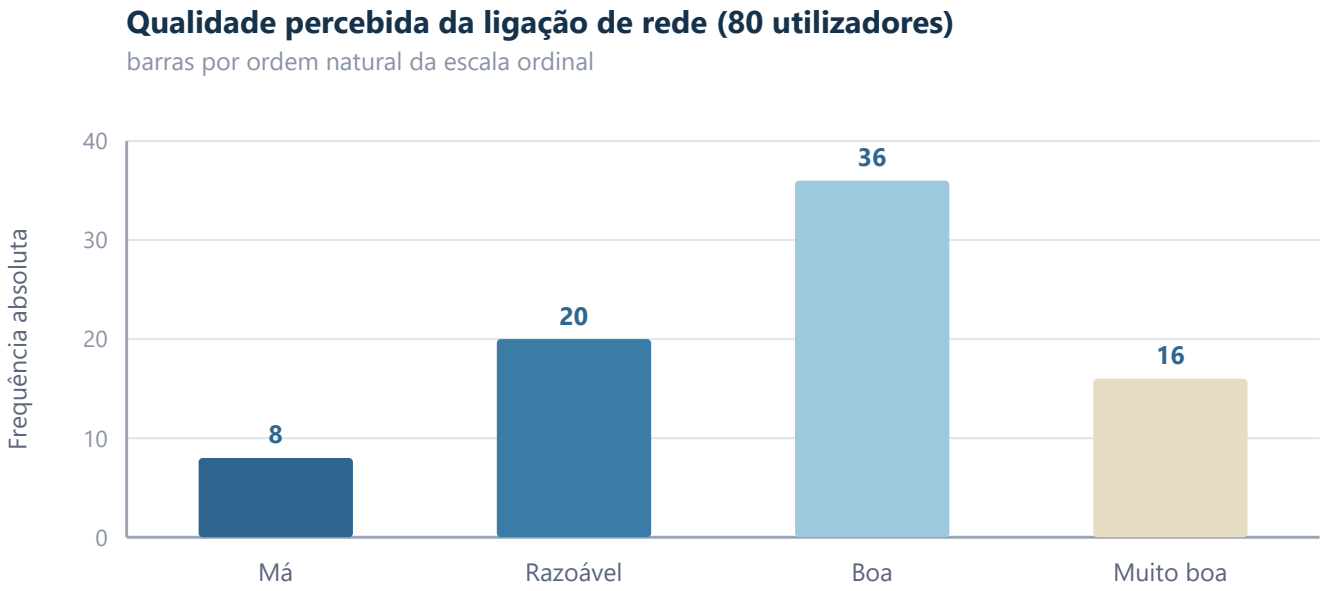


Figura 8 Aqui a ordem das barras *não* é arbitrária: segue a escala Má → Razoável → Boa → Muito boa.

3.4 Barras — variável discreta

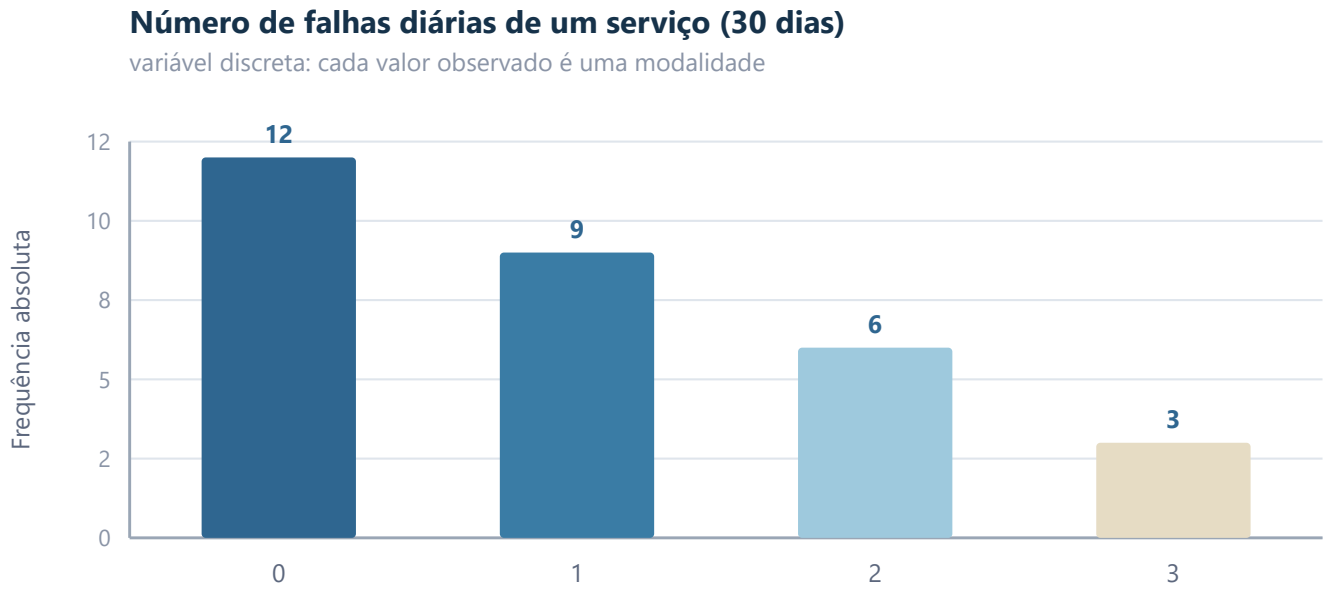


Figura 9 Cada valor observado (0, 1, 2, 3 falhas) é uma modalidade própria; a tabela preserva os valores exatos.

3.5 Histograma — variável contínua agrupada em classes

Quando existem muitos valores distintos, uma linha por valor seria pouco informativa. Agrupam-se os valores em classes: `[a, b[` significa $a \le x < b$.

$$A = x_{max} - x_{min} \quad \cdot \quad h \approx A \,/\, k \quad \cdot \quad k \approx 1 + 3{,}322 \log_{10}(n)$$

A = amplitude total · h = amplitude de classe · k = nº de classes (regra de Sturges)

COMO ESCOLHER O NÚMERO DE CLASSES

Tempos de resposta entre 121 e 238 ms → A = 117 ms. Para k = 6 classes, h ≈ 117/6 = 19,5 ms, adotando-se por conveniência **h = 20 ms**.

Com n = 100, a regra de Sturges dá k ≈ 1 + 3,322 × 2 ≈ 7,64 → cerca de **8 classes**.

Atenção: a escolha deve considerar a natureza dos dados, a dimensão da amostra e a facilidade de interpretação. A regra é uma orientação, não uma obrigação.

Tabela 13 tempos de resposta de 50 pedidos, agrupados em 6 classes de 20 ms

Classe (ms)	Centro c_i	F_i	f_i	F_a	f_a
[120, 140[	130	5	0,10	5	0,10
[140, 160[	150	11	0,22	16	0,32
[160, 180[	170	16	0,32	32	0,64
[180, 200[	190	10	0,20	42	0,84
[200, 220[	210	6	0,12	48	0,96
[220, 240[	230	2	0,04	50	1,00
Total	—	**50**	**1,00**	—	—

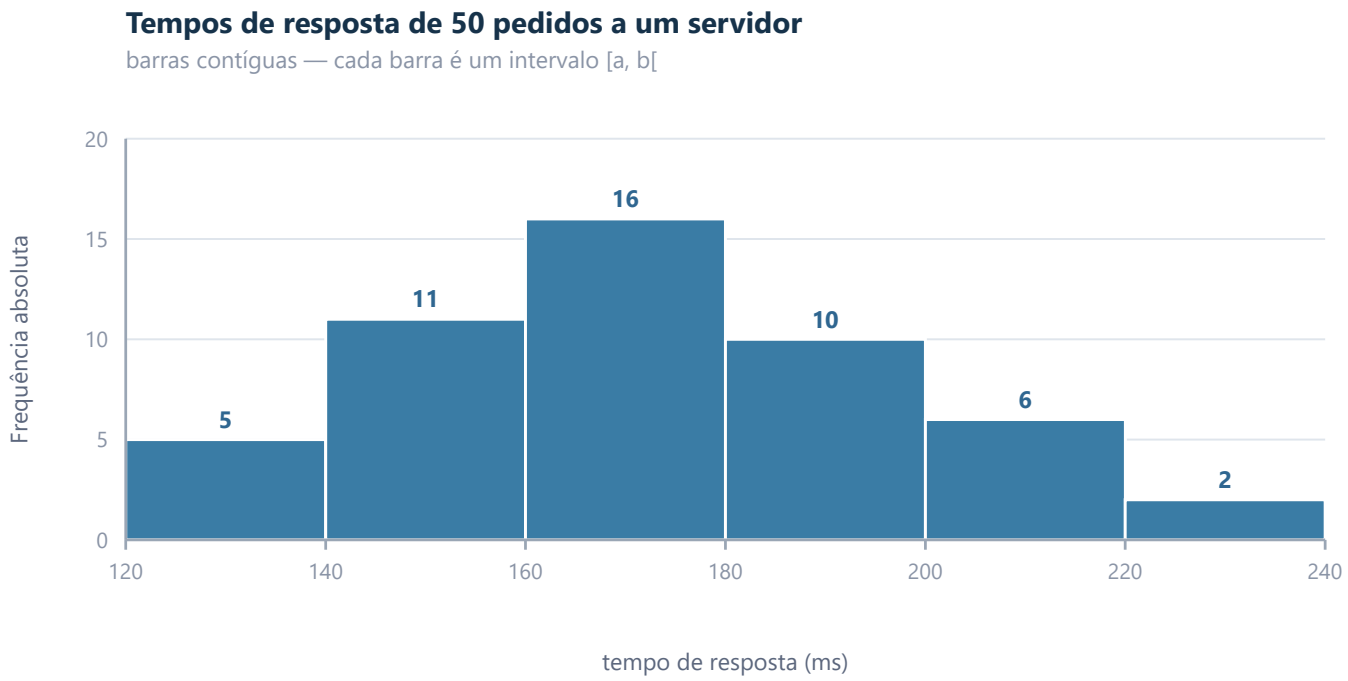


Figura 10 No histograma as barras são **contíguas**: representam intervalos adjacentes de valores, não categorias independentes.



Figura 11 A ogiva responde visualmente a perguntas como «que proporção dos pedidos tem tempo inferior a 200 ms?» — lê-se ≈ 0,84, ou seja 84%.

Tabela 14 barras ou histograma? — a distinção essencial

	Gráfico de barras	Histograma
Dados	categorias ou valores discretos	quantitativos contínuos
Barras	**separadas**	**contíguas**
Ordem	pode ser arbitrária (nominais)	classes ordenadas numericamente
O que a barra representa	uma categoria	um intervalo de valores

ERRO FREQUENTE

Um histograma **não** é um gráfico de barras «sem espaços». A diferença não é estética: no histograma a largura e a posição de cada barra têm significado numérico; nas barras, não.

3.6 Um gráfico correto pode ainda enganar

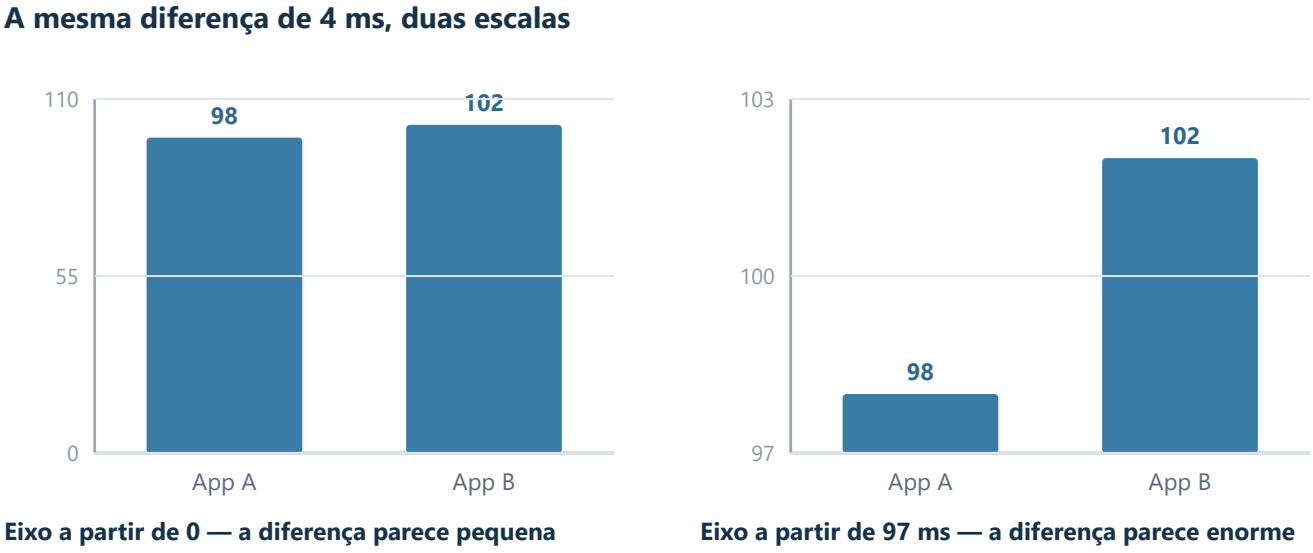


Figura 12 Duas aplicações com 98 ms e 102 ms. À esquerda, o eixo começa em 0 e a diferença é o que é. À direita, o eixo começa em 97 ms e a mesma diferença parece enorme.

> **Boa prática:** explicitar sempre a escala dos eixos e escolhê-la de modo a não exagerar nem a ocultar diferenças. Em gráficos de barras, um eixo que não começa em zero exige especial cuidado.

Parte 4 Resumir com um número

Uma medida de localização resume uma distribuição através de um valor que descreve a sua posição ou tendência central. Há quatro famílias, e cada uma responde a uma pergunta diferente.

Tabela 15 as quatro famílias de medidas de localização

Medida	A que pergunta responde	Lógica
Média	onde está o equilíbrio aritmético?	minimiza desvios quadráticos
Mediana	onde está a posição central?	minimiza desvios absolutos
Moda	qual é o valor mais frequente?	conta ocorrências
Quantis	que posições repartem a distribuição?	inversa da frequência acumulada

4.1 Média aritmética

$$\bar{x} = (1/n)\,\Sigma\, x_j \quad \cdot \quad \bar{x} = (\Sigma\, x_i F_i) \,/\, n = \Sigma\, x_i f_i \quad \cdot \quad \bar{x}_w = \Sigma\, w_j x_j \,/\, \Sigma\, w_j$$

dados individuais · com tabela de frequências · com pesos

Tabela 16 as três propriedades da média, com demonstração nos slides

Propriedade	Enunciado	Interpretação
1. Soma dos desvios	$\Sigma\,(x_j - \bar{x}) = 0$	os desvios positivos e negativos compensam-se exatamente
2. Transformação linear	se $y_j = a + bx_j$ então $\bar{y} = a + b\bar{x}$	somar 5 ms a cada latência aumenta a média 5 ms; duplicar os tempos duplica a média
3. Mínimos quadrados	$\Sigma\,(x_j - c)^2$ é mínima em $c = \bar{x}$	a média é o ponto que minimiza os desvios quadráticos

MÉDIA SIMPLES E MÉDIA PONDERADA

Dados individuais. Latências 18, 20, 22, 24, 26 ms → $\bar{x}$ = (18+20+22+24+26)/5 = **22 ms**.

Com tabela de frequências. Numa amostra de 10 programas (2 com 0 erros, 5 com 1 e 3 com 2): $\Sigma\, x_i F_i$ = 11 → $\bar{x}$ = 11/10 = **1,1 erros por programa**.

Ponderada. Avaliação de software: usabilidade 16 (peso 30%), segurança 14 (peso 50%), documentação 18 (peso 20%) → $\bar{x}_w$ = 0,30(16) + 0,50(14) + 0,20(18) = **15,4**.

4.2 Mediana

Ordenam-se os dados, $x_{(1)} \le \cdots \le x_{(n)}$:

$$\mathrm{Me} = x_{((n+1)/2)} \ \text{ se n ímpar} \quad \cdot \quad \mathrm{Me} = (x_{(n/2)} + x_{(n/2+1)})/2 \ \text{ se n par}$$

Exemplos: 3, 5, 7, 9, 12 → Me = 7 · 3, 5, 7, 9 → Me = (5+7)/2 = 6

- Divide a amostra ordenada em duas partes, com pelo menos metade das observações de cada lado.
- É **resistente a valores extremos**.
- Minimiza $\Sigma\,|x_j - c|$ — e para n par, qualquer c entre as duas observações centrais é minimizador.
- É adequada a dados quantitativos assimétricos e, como categoria central, a dados ordinais.

Contraste conceptual: a média está ligada a desvios *quadráticos*; a mediana a desvios *absolutos*. É essa diferença que explica a robustez de uma e a sensibilidade da outra.

MEDIANA A PARTIR DE FREQUÊNCIAS ACUMULADAS

Com x = 0 (F = 2, F_a = 2), x = 1 (F = 5, F_a = 7), x = 2 (F = 3, F_a = 10) e n = 10, procuramos as posições 5 e 6. Ambas correspondem a x = 1 → **Me = 1**.

A frequência acumulada permite localizar as observações centrais sem reconstruir toda a lista.

4.3 Moda

Valor ou modalidade com a maior frequência absoluta F_i. Nos dados 0, 1, 1, 1, 2, 2, 3 → **Mo = 1**.

- Pode haver uma moda, várias (bimodal, multimodal) ou nenhuma única.
- É a única medida aplicável a variáveis **qualitativas nominais**.

4.4 O impacto de uma só observação

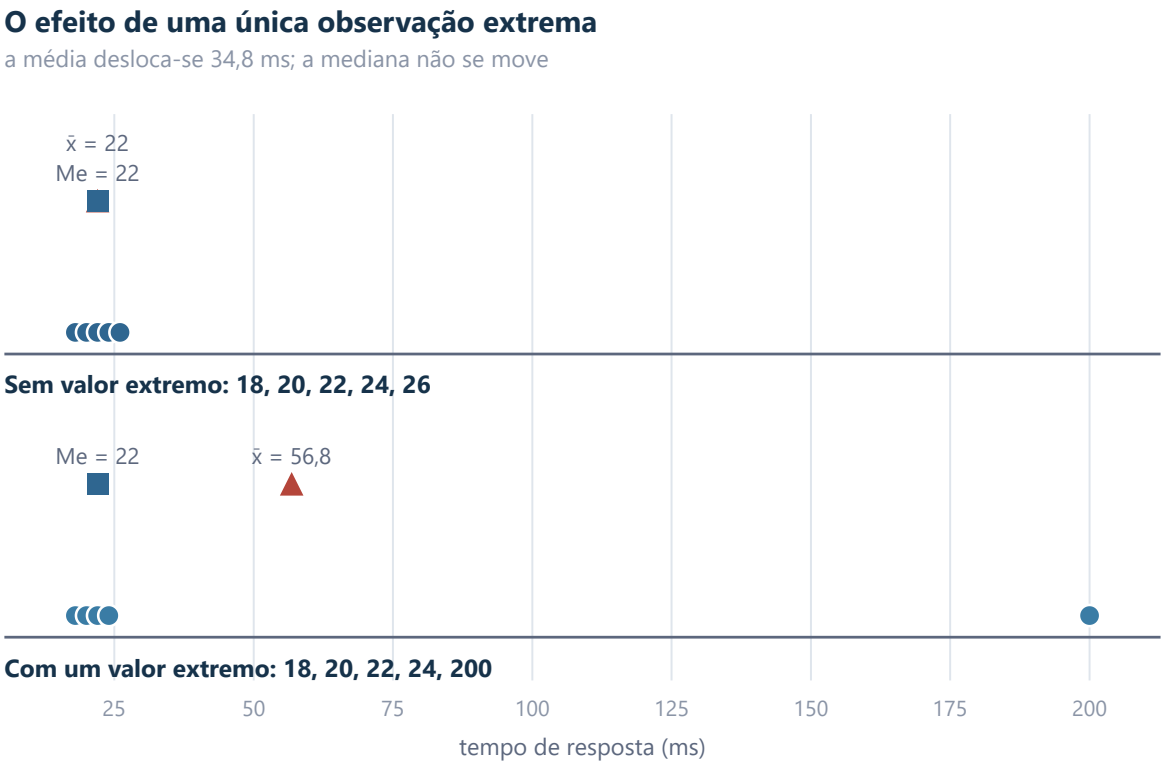


Figura 13 O mesmo conjunto com um único valor alterado de 26 para 200 ms. A média passa de 22 para 56,8 ms; a mediana mantém-se em 22 ms.

Tabela 17 sensibilidade da média a valores extremos

Conjunto	Média	Mediana	O que aconteceu
18, 20, 22, 24, 26	22	22	média e mediana coincidem — distribuição simétrica
18, 20, 22, 24, **200**	**56,8**	**22**	uma observação extrema deslocou a média 34,8 ms e não mexeu na mediana

Tabela 18 comparação das três medidas

Medida	Vantagem	Limitação
Média	usa todos os valores	influenciada por extremos
Mediana	resistente; posição central	não utiliza as distâncias entre todos os valores
Moda	serve para dados nominais	pode não ser única ou ser pouco informativa

> **Regra prática:** em distribuições assimétricas, apresentar média *e* mediana é mais informativo do que apresentar apenas uma delas. A diferença entre as duas é, ela própria, informação sobre a forma da distribuição.

4.5 Quantis: quartis, decis e percentis

Tabela 19 famílias de quantis

Família	Notação	Cortes	Uso típico
Quartis	Q_1, Q_2, Q_3	25%, 50%, 75%	caixa de bigodes, AIQ
Decis	D_1 … D_9	10%, 20%, …, 90%	análise por décimos
Percentis	P_1 … P_{99}	1%, 2%, …, 99%	níveis de serviço (ex.: P_{90})
Relação	$Q_2 = P_{50} = Me$	—	a mediana é o quantil de ordem 0,5

> $$Q(p) = x_{(\lceil np \rceil)}$$
>
> Convenção adotada: primeira observação cuja frequência relativa acumulada é pelo menos p

HÁ VÁRIAS CONVENÇÕES — E NÃO DÃO O MESMO

Manuais e software usam definições diferentes de quantil. Para p = 0,5, a mediana desta aula (média dos dois valores centrais quando n é par) pode diferir de Q(0,5) definido acima. É essencial dizer qual a convenção usada.

QUARTIS COM 9 TEMPOS (MS): 10, 12, 13, 15, 18, 19, 21, 25, 30

Tabela 20 quartis pela convenção adotada Q(p) = x([np])

Quantil	Cálculo	Resultado	Leitura
$Q_1 = Q(0{,}25)$	$x_{(3)}$	13	cerca de 25% não excedem 13 ms
$Q_2 = Q(0{,}50)$	$x_{(5)}$	18	metade dos tempos até 18 ms
$Q_3 = Q(0{,}75)$	$x_{(7)}$	21	cerca de 75% não excedem 21 ms

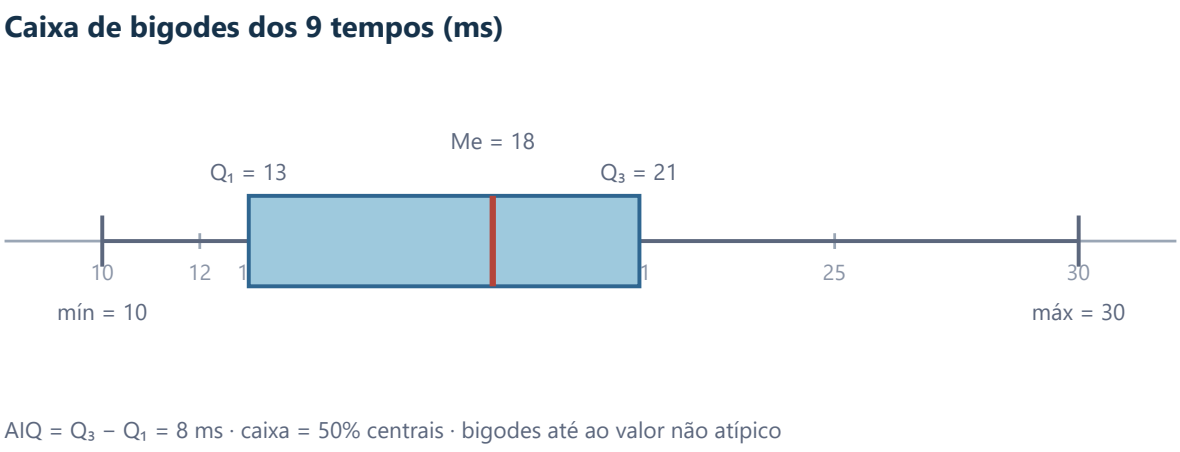


Figura 14 A caixa contém os 50% centrais das observações; AIQ = $Q_3 - Q_1$ = 21 − 13 = 8 ms.

PERCENTIS A PARTIR DE FREQUÊNCIAS ACUMULADAS

Frequências: 10 ms (F = 2, f_a = 0,20), 20 ms (F = 4, f_a = 0,60), 30 ms (F = 3, f_a = 0,90), 40 ms (F = 1, f_a = 1,00); n = 10.

$P_{75} = \min \{ x_i : f_a(x_i) \geq 0{,}75 \}$ = **30 ms** → pelo menos 75% das observações têm tempo não superior a 30 ms.

Parte 5 Quando só temos classes

Se os dados originais se perderam e só restam as classes, substituímos cada observação pelo **centro da classe** e interpolamos. O resultado é uma *aproximação*, não um valor exato.

$$\bar{x} \approx (\Sigma\, c_i F_i) \,/\, n$$

$c_i = (a_i + b_i)/2$ é o centro da classe

$$Me \approx L + h \cdot (n/2 - F_{a,ant}) \,/\, F_{med} \quad \cdot \quad Q(p) \approx L + h \cdot (np - F_{a,ant}) \,/\, F_{classe}$$

admitindo distribuição uniforme dentro da classe mediana

EXEMPLO RESOLVIDO — MÉDIA, MEDIANA E Q_3 APROXIMADOS

Classes: [0, 10[(c = 5, F = 2), [10, 20[(c = 15, F = 5), [20, 30[(c = 25, F = 3); n = 10.

Média. $\bar{x} \approx (5{\cdot}2 + 15{\cdot}5 + 25{\cdot}3)/10 = 100/10 =$ **16 ms**.

Mediana. Classe mediana [10, 20[→ L = 10, h = 10, $F_{a,ant} = 2$, $F_{med} = 5$: $Me \approx 10 + 10{\cdot}(5 - 2)/5 =$ **16 ms**.

Terceiro quartil. np = 7,5 → classe [20, 30[, L = 20, h = 10, $F_{a,ant} = 7$, $F_{classe} = 3$: $Q_3 \approx 20 + 10{\cdot}(7{,}5 - 7)/3 =$ **21,67 ms**.

PRECAUÇÃO COM DADOS AGRUPADOS

- A média por centros de classe e os quantis por interpolação são **estimativas**, não valores exatos dos dados originais.
- Classes muito largas podem esconder assimetrias e valores extremos.
- As estimativas dependem da organização das classes escolhida.
- Para cálculos exatos, conservar sempre os dados individuais.

Parte 6 Escolher e comunicar

6.1 Que medida usar

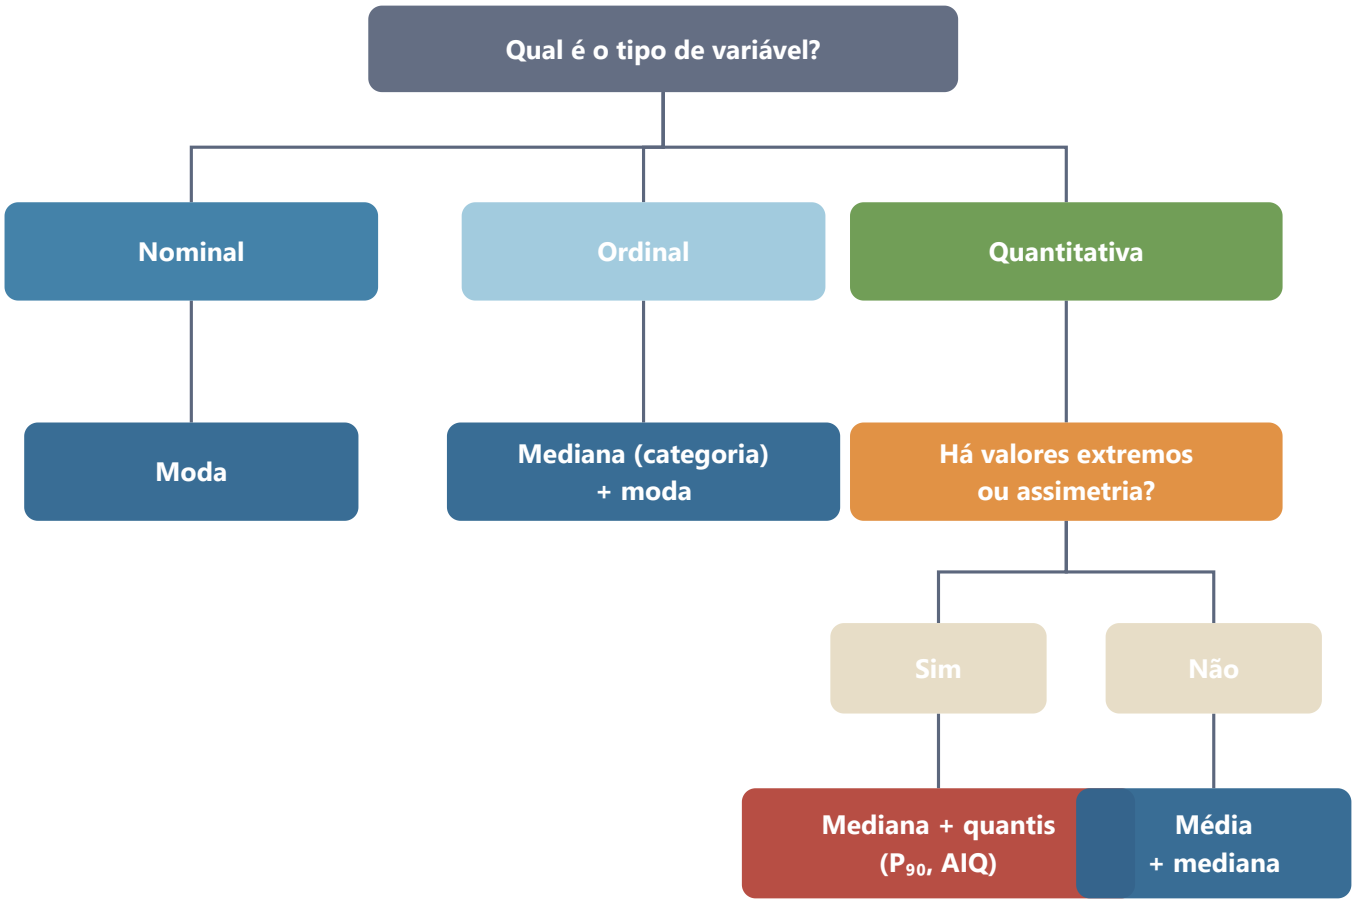


Figura 15 A escolha não é uma preferência pessoal: decorre do tipo de variável e da presença de valores extremos.

Tabela 21 tabela de decisão resumida

Situação	Medida(s) recomendada(s)
Variável nominal	Moda
Variável ordinal	Mediana (categoria) e moda
Dados quantitativos aproximadamente simétricos	Média e mediana
Dados quantitativos com valores extremos	Mediana e quantis; complementar com a média
Avaliação de níveis de serviço	Mediana e percentis elevados

6.2 Caso integrador: desempenho de um servidor

TEMPOS DE RESPOSTA (MS): 18, 19, 20, 21, 22, 23, 24, 25, 28, 200

1. Qual a média? E a mediana?

$\Sigma x_j = 400$ com $n = 10 \rightarrow \bar{x} =$ **40 ms**.

Ordenados, os dois centrais são 22 e 23 → Me = **22,5 ms**.

2. Qual resume melhor o tempo típico?

A **mediana**: 9 dos 10 pedidos ficam entre 18 e 28 ms, e um único pedido de 200 ms arrasta a média para 40 ms. O valor típico é ≈ 22,5 ms, não 40 ms.

3. Porque comunicar também um percentil elevado?

Porque a mediana esconde a cauda. Um P_{90} (ou P_{95}) mostra o que sentem os utilizadores mais afetados — exatamente o que a média estava a tentar dizer, mas de forma distorcida.

Como comunicar bem um resultado: dar a mediana como valor típico, um percentil elevado para a cauda, e a média apenas como complemento, explicando que está inflacionada. Três números, três perguntas diferentes.

Parte 7 Erros frequentes e verificação rápida

7.1 Erros frequentes

Tabela 22 os erros assinalados nos slides e como os evitar

Erro	Porque está errado	Como evitar
Codificar categorias com números e tratá-las como quantitativas	a média de sistemas operativos codificados 1, 2, 3 não tem interpretação substantiva	verificar sempre a escala antes de calcular
Somar a coluna F_a	somar frequências acumuladas não tem significado	só $\Sigma F_i = n$ e $\Sigma f_i = 1$ fazem sentido
Usar acumuladas em variáveis nominais	sem ordem natural, a acumulação é arbitrária	acumular só faz sentido com variáveis ordinais ou quantitativas
Tratar um histograma como barras sem espaços	a largura e a posição das barras têm significado numérico	confirmar que as classes são intervalos adjacentes
Apresentar só a média em dados assimétricos	uma observação extrema desloca-a muito	apresentar média e mediana, ou mediana e quantis
Tomar estimativas de dados agrupados como exatas	dependem dos centros de classe e da interpolação	assinalar explicitamente que são aproximações
Eixos truncados a exagerar diferenças	um gráfico correto pode ser visualmente enganador	explicitar a escala; cuidado com eixos que não começam em 0

7.2 Verificação rápida

Tabela 23 quatro perguntas de controlo com resposta e justificação

Pergunta	Resposta	Justificação
É possível calcular a média de sistemas operativos codificados 1, 2 e 3?	**Não**	não tem interpretação substantiva — a variável é nominal
A mediana muda necessariamente quando aumenta o máximo?	**Não**	a mediana só depende da posição central
O que significa P_{90} = 120 ms?	≈ 90% dos tempos	não excedem 120 ms; o limiar deixa 10% acima
Em dados agrupados, a média com centros de classe é exata?	**Em geral, não**	é uma aproximação que depende das classes

7.3 O essencial em dez linhas

1. Classificar primeiro: população, unidade estatística, amostra.
2. Identificar o tipo de variável e a escala — tudo o resto depende disso.
3. Organizar em tabela de frequências: F_i, f_i, F_a, f_a.
4. Acumular só quando existe ordem natural.
5. Muitos valores distintos → agrupar em classes de igual amplitude.
6. Escolher o gráfico pela natureza da variável, não pelo gosto.
7. Média para o equilíbrio; mediana para a posição; moda para categorias; quantis para posições.
8. Havendo extremos, a mediana descreve melhor o típico do que a média.
9. Em dados agrupados, tudo é aproximado — dizê-lo.
10. Comunicar sempre mais do que um número quando a distribuição é assimétrica.

Resumo visual produzido por leitura integral da camada de texto de `estatística.pdf` (87 slides, LaTeX Beamer, autor: Licenciatura em Engenharia Informática). Todos os conjuntos de dados, tabelas de frequência e resultados numéricos reproduzem os do documento original; os gráficos foram reconstruídos a partir desses valores. Nenhum ficheiro original foi alterado.